

BỘ GIÁO DỤC VÀ ĐÀO TẠO BỘ NÔNG NGHIỆP VÀ MÔI TRƯỜNG

TRƯỜNG ĐẠI HỌC THỦY LỢI



HỌ VÀ TÊN: TRẦN HỒNG SƠN

**NGHIÊN CỨU VÀ XÂY DỰNG HỆ THỐNG TRỢ LÝ ẢO HỒ TRỢ TUYỂN
SINH CHO TRƯỜNG ĐẠI HỌC THỦY LỢI DỰA TRÊN KỸ THUẬT RAG**

ĐỒ ÁN TỐT NGHIỆP/KHÓA LUẬN TỐT NGHIỆP

HÀ NỘI, NĂM 2026

BỘ GIÁO DỤC VÀ ĐÀO TẠO BỘ NÔNG NGHIỆP VÀ MÔI TRƯỜNG

TRƯỜNG ĐẠI HỌC THỦY LỢI

TRẦN HỒNG SƠN

**NGHIÊN CỨU VÀ XÂY DỰNG HỆ THỐNG TRỢ LÝ ẢO
HỖ TRỢ TUYỂN SINH CHO TRƯỜNG ĐẠI HỌC THỦY LỢI
DỰA TRÊN KỸ THUẬT RAG**

Ngành : Công Nghệ Thông Tin

Mã số: 7480201

NGƯỜI HƯỚNG DẪN: TS. Lý Anh Tuấn

HÀ NỘI, NĂM 2026



CỘNG HOÀ XÃ HỘI CHỦ NGHĨA VIỆT NAM

Độc lập - Tự do - Hạnh phúc



NHIỆM VỤ ĐỒ ÁN TỐT NGHIỆP

Họ tên sinh viên: Trần Hồng Sơn

Hệ đào tạo: Đại học chính quy

Lớp: 61TH1

Ngành: Công nghệ thông tin

Khoa: Công nghệ thông tin

1- TÊN ĐỀ TÀI:

NGHIÊN CỨU VÀ XÂY DỰNG HỆ THỐNG TRỢ LÝ ẢO HỒ TRỢ TUYỂN SINH
CHO TRƯỜNG ĐẠI HỌC THỦY LỢI DỰA TRÊN KỸ THUẬT RAG

2- CÁC TÀI LIỆU

- [1] P. Lewis et al., "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," NeurIPS, 2020.
- [2] A. Vaswani et al., "Attention Is All You Need," NeurIPS, 2017.
- [3] Y. Gao et al., "Retrieval-Augmented Generation for Large Language Models: A Survey," arXiv preprint, 2024.
- [4] J. Devlin et al., "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding," NAACL, 2019.
- [5] T. Brown et al., "Language Models are Few-Shot Learners," NeurIPS, 2020.
- [6] LangChain AI, "LangChain Documentation," 2024.
- [7] Chroma, "ChromaDB Documentation," 2024.
- [8] Google, "Google Gemini API Reference," 2024.

3 - NỘI DUNG CÁC PHẦN THUYẾT MINH VÀ TÍNH TOÁN:

Nội dung các phần	Tỷ lệ
Tìm hiểu tổng quan về bài toán hướng nghiệp, các công nghệ liên quan (RAG, LLM, Vector Database).	20%
Phân tích thiết kế hệ thống, xác định yêu cầu chức năng, phi chức năng và kiến trúc giải pháp.	30%
Thu thập, tiền xử lý và xây dựng cơ sở dữ liệu hướng nghiệp đa phương thức.	20%
Cài đặt và triển khai hệ thống (chatbot Zalo, Web Dashboard, backend RAG).	20%
Đánh giá kết quả, viết báo cáo tổng kết và chuẩn bị tài liệu thuyết minh.	10%

4. GIÁO VIÊN HƯỚNG DẪN TỪNG PHẦN

Phần	Họ tên giáo viên hướng dẫn
Toàn bộ dự án	TS. Lý Anh Tuấn

5. NGÀY GIAO NHIỆM VỤ ĐỒ ÁN TỐT NGHIỆP

Ngày tháng năm 2026

Trưởng Bộ môn

(Ký và ghi rõ Họ tên)

Giáo viên hướng dẫn chính

(Ký và ghi rõ Họ tên)

TS. Lý Anh Tuấn

Nhiệm vụ Đồ án tốt nghiệp đã được Hội đồng thi tốt nghiệp của Khoa thông qua

Ngày. . . . tháng. . . . năm 2026

Chủ tịch Hội đồng

(Ký và ghi rõ Họ tên)

Sinh viên đã hoàn thành và nộp bản Đồ án tốt nghiệp cho Hội đồng thi ngày... tháng... năm 2026.

Sinh viên làm Đồ án tốt nghiệp

(Ký và ghi rõ Họ tên)



TRƯỜNG ĐẠI HỌC THỦY LỢI
KHOA CÔNG NGHỆ THÔNG TIN

ĐỀ CƯƠNG ĐỒ ÁN TỐT NGHIỆP

TÊN ĐỀ TÀI: Nghiên cứu và xây dựng hệ thống trợ lý ảo hỗ trợ tuyển sinh cho Trường Đại học Thủy Lợi dựa trên kỹ thuật RAG

Sinh viên thực hiện: Trần Hồng Sơn

Lớp: 61TH1

Mã sinh viên: 1951060985

Số điện thoại: 0866113953

Email: 1951060985@e.tlu.edu.vn

Giáo viên hướng dẫn: TS. Lý Anh Tuấn

Thời gian thực hiện: ... tuần: từ ngày: 31/03/2026 đến ngày: 30/06/2026

TÓM TẮT ĐỀ TÀI

Đề tài: Nghiên cứu và xây dựng hệ thống trợ lý ảo hỗ trợ tuyển sinh cho Trường Đại học Thủy Lợi dựa trên kỹ thuật RAG

Sinh viên: Trần Hồng Sơn (61TH1)

GVHD: TS. Lý Anh Tuấn

Đề tài tập trung thiết kế và phát triển hệ thống trợ lý ảo hỗ trợ công tác tư vấn tuyển sinh tại Trường Đại học Thủy Lợi, hướng tới mục tiêu tự động hóa việc giải đáp thông tin đa

phân luồng. Triển khai cơ chế phân tách và lập chỉ mục đa luồng, hỗ trợ chuyển đổi linh hoạt các định dạng văn bản (PDF, DOCX) thành cơ sở dữ liệu vector. Hệ thống truy xuất nhanh chóng các điều khoản quy định giáo dục mà không phá vỡ cấu trúc ngữ nghĩa gốc.

Sử dụng mô hình ngôn ngữ lớn của Google Gemini, bắt buộc mạng nơ-ron trả lời dựa trên tài liệu cung cấp. Hệ thống giải quyết tốt bài toán lọc câu hỏi ngoài phạm vi nghiệp vụ giáo dục nhằm ngăn chặn hiện tượng cung cấp thông tin sai lệch ngoài dữ liệu gốc của nhà trường.

Cấu trúc đề án gồm 4 chương. Chương 1 trình bày cơ sở lý thuyết về bài toán hỏi đáp và mô hình RAG. Chương 2 phân tích yêu cầu thiết kế hệ thống. Chương 3 triển khai các luồng xử lý kỹ thuật trên máy chủ FastAPI. Chương 4 thiết lập kịch bản đánh giá để kiểm thử năng lực truy xuất, tốc độ phản hồi và khả năng phòng chống thông tin ảo giác của hệ thống.

KẾT QUẢ DỰ KIẾN

1. Hoàn thiện quyền đề án tốt nghiệp với đầy đủ cơ sở lý thuyết về RAG, cơ sở dữ liệu vector và quy trình phân tích thiết kế hệ thống.
2. Xây dựng được website tích hợp chatbot trợ lý ảo đáp ứng đầy đủ các yêu cầu đã đề ra.
3. Tiến hành triển khai thử nghiệm website tích hợp trợ lý ảo trên môi trường thực tế, kiểm tra tính chính xác của câu trả lời dựa trên tập dữ liệu mẫu.
4. Đánh giá chất lượng câu trả lời của hệ thống theo các metric tiêu chuẩn: Context Precision, Context Recall và Answer Relevance đạt kết quả từ 0.8 (80%) trở lên; riêng chỉ số Faithfulness đạt mức tiệm cận 1.0 (100%).

TIẾN ĐỘ THỰC HIỆN

TT	Thời gian	Nội dung công việc	Kết quả dự kiến đạt được
1	01/04/2026 - 15/04/2026	Nghiên cứu lý thuyết, thu thập, tiền xử lý dữ liệu và phân tích thiết kế kiến trúc hệ thống.	Cơ sở dữ liệu chuẩn hóa, tài liệu thiết kế hệ thống.
2	16/04/2026 - 15/05/2026	Lập trình xây dựng pipeline RAG, cơ sở dữ liệu vector và phát triển giao diện tích hợp.	Pipeline RAG hoàn chỉnh
3	16/05/2026 - 15/06/2026	Xây dựng bộ dữ liệu kiểm thử, đo lường đánh giá hệ thống theo các metric và tinh chỉnh tối ưu.	Bảng kết quả đánh giá metric, hệ thống được tối ưu.
4	16/06/2026 - 30/06/2026	Phân tích kết quả thực nghiệm, viết báo cáo tổng kết và chuẩn bị tài liệu bảo vệ.	Báo cáo đồ án hoàn chỉnh.

GẤY BÌA ĐỒ ÁN TỐT NGHIỆP, KHÓA LUẬN TỐT NGHIỆP

HỌ VÀ TÊN: Trần Hồng Sơn

ĐỒ ÁN/KL. TỐT NGHIỆP

HÀ NỘI, NĂM 2026

Nhiệm vụ Đồ án tốt nghiệp đã được Hội đồng thi tốt nghiệp của Khoa thông qua

Ngày. . . . tháng. . . . năm 2026

Chủ tịch Hội đồng

(Ký và ghi rõ Họ tên)

Sinh viên đã hoàn thành và nộp bản Đồ án tốt nghiệp cho Hội đồng thi ngày... tháng... năm 2026.

Sinh viên làm Đồ án tốt nghiệp

(Ký và ghi rõ Họ tên)

LỜI CAM ĐOAN

Em xin cam đoan đây là Đồ án tốt nghiệp của em. Các kết quả, nội dung trong Đồ án tốt nghiệp này là trung thực, không sao chép từ bất kỳ nguồn nào vào dưới bất kì hình thức nào. Việc tham khảo tài liệu trong bài được được ghi rõ trong phần tài liệu tham khảo theo quy định của nhà trường.

Sinh viên thực hiện

Trần Hồng Sơn

LỜI CẢM ƠN

Trước tiên, em xin bày tỏ lòng biết ơn sâu sắc tới toàn thể thầy cô trong Khoa Công nghệ Thông tin – Trường Đại học Thủy Lợi, những người đã không chỉ truyền đạt cho em kiến thức chuyên môn vững vàng, mà còn giúp em rèn luyện tư duy, tinh thần học tập và tác phong làm việc chuyên nghiệp trong suốt quá trình học tập tại trường.

Em đặc biệt tri ân TS. Lý Anh Tuấn, người đã tận tâm hướng dẫn, luôn đồng hành, góp ý và định hướng cho em trong quá trình thực hiện đề án tốt nghiệp này. Những chia sẻ và chỉ dẫn của thầy là nguồn động lực lớn giúp em hoàn thành đề tài.

Do còn hạn chế về kinh nghiệm thực tế cũng như kiến thức chuyên sâu, đề án của em không tránh khỏi những thiếu sót. Em rất mong nhận được những ý kiến đóng góp quý báu từ quý thầy cô để hoàn thiện hơn đề tài này.

Một lần nữa, em xin chân thành cảm ơn!

MỤC LỤC

TÓM TẮT ĐỀ TÀI	iv
MỤC LỤC	4
MỤC LỤC ẢNH	8
MỤC LỤC BẢNG BIỂU	9
DANH MỤC CÁC TỪ VIẾT TẮT VÀ GIẢI THÍCH THUẬT NGỮ.....	10
PHẦN MỞ ĐẦU	14
CHƯƠNG 1: CƠ SỞ LÝ THUYẾT VÀ TỔNG QUAN NGHIÊN CỨU	17
1.1. Tổng quan về trợ lý ảo và bài toán hỏi đáp tự động.....	17
1.2. LLM và kiến trúc Transformer.....	18
1.2.1. Kiến trúc Transformer và cơ chế tự chú ý	18
1.2.2. Vòng đời huấn luyện của LLM.....	19
1.2.3. Hạn chế của LLM trong hệ thống tri thức đóng	19
1.3. Kỹ thuật sinh văn bản tăng cường truy xuất.....	20
1.3.1. Khái niệm và kiến trúc cốt lõi.....	20
1.3.2. Tiền xử lý và các chiến lược phân mảnh	21
1.4. Vector Database và kỹ thuật nhúng.....	22
1.4.1. Không gian vector và độ đo khoảng cách.....	22
1.4.2. Thuật toán tìm kiếm xấp xỉ.....	22
1.4.3. Đánh giá các hệ quản trị vector	23
1.5. Tổng quan nghiên cứu liên quan	24
1.6. Các công nghệ sử dụng trong đề tài	25
CHƯƠNG 2: PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG.....	26
2.1. Phân tích yêu cầu hệ thống.....	26

2.1.1. Yêu cầu chức năng.....	26
2.1.2. Yêu cầu phi chức năng.....	27
2.2. Đặc tả Use Case và phân tích tương tác	28
2.2.1. Biểu đồ Use Case tổng quát.....	28
2.2.2. Đặc tả chi tiết luồng cập nhật tri thức.....	28
2.3. Thiết kế cấu trúc dữ liệu và CSDL	29
2.3.1. Sơ đồ ERD	29
2.3.2. Cấu trúc lưu trữ vector.....	30
2.4. Thiết kế kiến trúc hệ thống tổng thể.....	30
2.5. Phân tích chi tiết luồng xử lý tương tác.....	30
2.5.1. Luồng xử lý câu hỏi người dùng	31
2.5.2. Luồng tiền xử lý và cập nhật tri thức.....	31
2.6. Đặc tả giao diện lập trình ứng dụng (API)	33
2.7. Thiết kế kỹ thuật định hướng mô hình	33
2.8. Thiết kế giao diện và nền tảng tương tác.....	34
CHƯƠNG 3: TRIỂN KHAI HỆ THỐNG	36
3.1. Thiết lập môi trường phát triển.....	36
3.2. Triển khai phân hệ quản trị người dùng	36
3.2.1. Cơ chế xác thực và mã hóa	37
3.2.2. Quản lý vòng đời tài khoản và lưu vết.....	37
3.3. Triển khai phân hệ tự động thu thập dữ liệu	37
3.3.1. Kiến trúc luồng thu thập dữ liệu	38
3.3.2. Xử lý đa luồng và tạo tài liệu động.....	38
3.4. Triển khai phân hệ quản trị kho tri thức và dữ liệu vector	38

3.4.1. Cơ chế xóa và ghi đè thông minh	38
3.4.2. Thống kê và xử lý tệp rác	39
3.5. Triển khai cơ chế tối ưu hóa hệ thống	39
3.5.1. Cơ chế Semantic Cache	39
3.5.2. Kiến trúc đa phương thức và cơ chế chống quá tải	40
3.5.3. Cơ chế dự phòng thu thập tin nhắn.....	40
3.6. Triển khai giao diện lập trình ứng dụng	40
3.7. Triển khai giao diện quản trị và ứng dụng người dùng	41
3.7.1. Giao diện người dùng trên nền tảng nhắn tin	41
3.7.2. Bảng điều khiển quản trị tổng quan (Dashboard).....	42
3.7.3. Phân hệ quản lý tài liệu và mã hóa dữ liệu	42
3.7.4. Phân hệ thu thập dữ liệu tự động (Web Scraper).....	43
3.7.5. Giao diện kiểm thử hệ thống (Chat Tester)	44
3.7.6. Phân hệ quản lý người dùng	44
3.7.7. Giao diện quản lý từ viết tắt	45
3.7.8. Kiểm thử tiền xử lý (Query Test)	46
CHƯƠNG 4: THỬ NGHIỆM VÀ ĐÁNH GIÁ.....	47
4.1. Thiết kế phương pháp đánh giá	47
4.1.1. Phân loại tập dữ liệu kiểm thử	47
4.1.2. Tiêu chí đánh giá chất lượng sinh.....	47
4.1.3. Kịch bản kiểm thử hiệu năng tối ưu hóa.....	47
4.2. Kết quả thử nghiệm	48
4.2.1. Đánh giá độ chính xác	48
4.2.2. Đánh giá hiệu năng và cơ chế tối ưu hóa.....	48

4.3. Phân tích kết quả và thảo luận.....	49
4.4. Minh họa hoạt động hệ thống.....	50
CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN.....	52
TÀI LIỆU THAM KHẢO	55

MỤC LỤC ẢNH

Hình 2.1: Biểu đồ Use Case tổng quát của hệ thống	28
Hình 2.2: Sơ đồ ERD cho phân hệ quản trị CSDL nền	29
Hình 2.3: Sơ đồ kiến trúc tổng thể ba tầng phân tán	30
Hình 2.4: Biểu đồ tuần tự quá trình truy xuất và sinh văn bản.....	31
Hình 2.5: Sơ đồ luồng cập nhật tài liệu và nhúng tri thức.....	33
Hình 2.6: Giao diện tương tác người dùng trên nền tảng nhắn tin	34
Hình 2.7: Giao diện quản trị tri thức trên Web Admin Dashboard	35
Hình 3.1: Sơ đồ cấu trúc thư mục dự án.....	36
Hình 3.2: Hệ thống trợ lý ảo đang tư vấn trực tiếp trên nền tảng Zalo	42
Hình 3.3: Bảng điều khiển quản trị tổng quan trên Web Admin Dashboard	42
Hình 3.4: Giao diện quản trị tri thức và tải lên tài liệu.....	43
Hình 3.5: Giao diện điều khiển bộ tự động thu thập dữ liệu	44
Hình 3.6: Giao diện kiểm thử trợ lý ảo (Chat Tester) dành cho quản trị viên.....	44
ssHình 3.7: Giao diện phân hệ quản lý người dùng	45
Hình 3.8: Giao diện quản lý và định nghĩa từ viết tắt	46
Hình 3.9: Giao diện kiểm thử luồng tiền xử lý câu hỏi (Query Test)	46
Hình 4.1: Hệ thống trợ lý ảo đang tư vấn trực tiếp trên nền tảng nhắn tin.....	50
Hình 4.2: Giao diện nạp dữ liệu tri thức tự động trên Web Admin Dashboard	51

MỤC LỤC BẢNG BIỂU

Bảng 1.1: So sánh các phương pháp điều khiển LLM	21
Bảng 1.2: So sánh thông số hệ quản trị Vector Database.....	23
Bảng 4.1: Kết quả đánh giá hiệu năng trên tập truy vấn	48
Bảng 4.2: Đánh giá hiệu năng của Semantic Cache	48
Bảng 5.1: Đối chiếu kết quả thực hiện so với mục tiêu đề tài.....	53

DANH MỤC CÁC TỪ VIẾT TẮT VÀ GIẢI THÍCH THUẬT NGỮ

1. Danh mục từ viết tắt

Từ viết tắt	Cụm từ đầy đủ tiếng Anh	Giải nghĩa tiếng Việt
AI	Artificial Intelligence	AI
API	Application Programming Interface	Giao diện lập trình ứng dụng
CSTT	-	Cơ sở tri thức
CSDL	Database	Cơ sở dữ liệu
LLM	Large Language Model	LLM
MOS	Mean Opinion Score	Chỉ số đánh giá trải nghiệm người dùng
NLP	Natural Language Processing	Xử lý ngôn ngữ tự nhiên
RAG	Retrieval-Augmented Generation	Kỹ thuật sinh văn bản có tăng cường truy xuất
RAGAS	Retrieval Augmented Generation Assessment	Khung phần mềm đánh giá tự động hệ thống RAG
RLHF	Reinforcement Learning from Human Feedback	Học tăng cường từ phản hồi của người dùng
UI	User Interface	Giao diện người dùng
UX	User Experience	Trải nghiệm người dùng

2. Giải thích thuật ngữ

Thuật ngữ tiếng Anh	Giải nghĩa tiếng Việt	Mô tả
Answer Relevance	Answer Relevancy	Đánh giá mức độ câu trả lời đi thẳng vào trọng tâm và giải quyết trực tiếp truy vấn của người dùng.
Chunk	Phân đoạn / Mảnh tài liệu	Một phần nhỏ của văn bản gốc được cắt ra để tối ưu hóa việc nhúng và truy xuất trong không gian vector.
Context Precision	Context Precision	Đánh giá tỷ lệ thông tin hữu ích và có giá trị thực sự nằm trong các đoạn tài liệu được truy xuất.
Context Recall	Độ bao phủ ngữ cảnh	Đánh giá khả năng hệ thống truy xuất đầy đủ tất cả các thông tin cần thiết để giải quyết trọn vẹn truy vấn.
Decision Tree	Cây quyết định	Cấu trúc thuật toán rẽ nhánh dùng trong các hệ thống dựa trên quy tắc tĩnh.
Faithfulness	Độ trung thành	Đánh giá mức độ câu trả lời bám sát nguồn tài liệu gốc, không tự bịa đặt hay suy diễn sai lệch.
Fixed-size Chunking	Phân rã theo kích thước có định	Chiến lược cắt tài liệu thành các khối có số lượng ký tự bằng nhau.

Hallucination	Ảo giác	Hiện tượng LLM tự sinh ra thông tin sai lệch, không có cơ sở thực tế nhưng được trình bày một cách thuyết phục.
Intent Classification	Phân loại ý định	Quá trình nhận diện và phân nhóm các phát ngôn của người dùng vào từng mục tiêu giao tiếp cụ thể.
Intent	Ý định	Mục tiêu hoặc nhu cầu giao tiếp cốt lõi ẩn sau mỗi câu hỏi của người dùng.
LLM-as-a-judge	LLM làm giám khảo	Phương pháp sử dụng chính LLM để tự động chấm điểm và đánh giá chất lượng câu trả lời.
Pattern Matching	Đối sánh mẫu	Kỹ thuật nhận diện ngôn ngữ thông qua việc tìm kiếm sự trùng khớp với các khuôn mẫu định sẵn.
Prompt Engineering	Kỹ thuật định hướng mô hình	Phương pháp tinh chỉnh và thiết kế câu lệnh đầu vào để tối ưu hóa và điều khiển hành vi của LLM.
Query Rewriting	Viết lại câu hỏi	Kỹ thuật cấu trúc lại ngữ nghĩa truy vấn nhằm duy trì độ chuẩn xác khi tìm kiếm trong cơ sở dữ liệu.
Query Template	Khung mẫu truy vấn	Cấu trúc định dạng sẵn dùng để kết hợp thông tin truy xuất và câu hỏi thành một truy vấn thống nhất.
Recursive Chunking	Phân rã đệ quy	Chiến lược cắt tài liệu đệ quy theo các phân cách đoạn văn, câu, từ để giữ lại tối đa ngữ cảnh.
Reranking	Xếp hạng lại	Kỹ thuật đánh giá và sắp xếp lại thứ tự ưu tiên của các tài liệu nhằm tăng cường độ chuẩn xác.

Self-Attention	Cơ chế tự chú ý	Kỹ thuật giúp mạng nơ-ron đánh giá sự liên quan của tất cả các từ trong cùng một câu để nắm bắt ngữ cảnh.
Semantic Chunking	Phân rã theo ngữ nghĩa	Chiến lược cắt tài liệu dựa trên phân tích cấu trúc ngữ nghĩa hoặc dấu hiệu tiêu đề.
System Instruction	Chỉ thị hệ thống	Những quy tắc cốt lõi được thiết lập ngầm để quy định vai trò, ngữ điệu và ranh giới hoạt động của mô hình.
Two-stage retrieval	Truy xuất hai giai đoạn	Kiến trúc tìm kiếm kết hợp thu hẹp phạm vi ở giai đoạn đầu và xếp hạng lại tài liệu ở giai đoạn sau.
Utterance	Câu phát ngôn	Đơn vị hội thoại hoàn chỉnh hoặc chuỗi văn bản đầu vào do người dùng cung cấp.

PHẦN MỞ ĐẦU

1. Lý do chọn đề tài

Hiện nay, Trường Đại học Thủy Lợi tiếp nhận lượng lớn yêu cầu tư vấn trong mỗi kỳ tuyển sinh. Nội dung thắc mắc trải rộng từ phương thức xét tuyển, chỉ tiêu, điểm chuẩn đến học phí và học bổng. Tình trạng thông tin phân tán trên nhiều hệ thống văn bản, đề án và thông báo khiến người học mất nhiều thời gian tra cứu. Thực trạng này đòi hỏi nhân sự tuyển sinh phải liên tục đối chiếu qua nhiều tài liệu để trả lời các câu hỏi mang tính lặp lại.

Để tự động hóa quy trình này, các trường từng áp dụng chatbot tĩnh. Việc sử dụng chatbot tĩnh gặp khó khăn khi sinh viên hỏi câu ghép phức tạp hoặc dùng ngôn ngữ tự do. Phí bảo trì cũng gia tăng vì kỹ sư phải sửa mã nguồn mỗi lần nhà trường cập nhật quy chế.

Kỹ thuật RAG (Lewis và cộng sự, 2020) kết hợp sức mạnh tổng hợp ngôn ngữ của LLM với cơ sở tri thức (CSTT) độc lập. Nhờ tách khỏi cơ sở dữ liệu (CSDL) và mô hình suy luận, hệ thống tránh được hiện tượng ảo giác sinh ra thông tin sai lệch. Khi quy chế thay đổi, quản trị viên chỉ cần nạp lại tài liệu văn bản mà không phải huấn luyện lại mạng nơ-ron. Xuất phát từ nhu cầu thực tiễn đó, đề tài "Nghiên cứu và xây dựng hệ thống trợ lý ảo hỗ trợ tuyển sinh cho Trường Đại học Thủy Lợi dựa trên kỹ thuật RAG" được triển khai.

2. Mục tiêu nghiên cứu

Nghiên cứu kiến trúc hệ thống RAG, bao gồm các phương pháp phân mảnh văn bản, tối ưu hóa quá trình nhúng dữ liệu và truy xuất trên Vector Database. Đề tài tập trung đánh giá mức độ tương thích của các mô hình nhúng và LLM đối với ngôn ngữ tiếng Việt trong lĩnh vực giáo dục.

Xây dựng hệ thống trợ lý ảo hoạt động trên nền tảng Zalo, hỗ trợ giải đáp thông tin tuyển sinh ở các bậc đại học, thạc sĩ và tiến sĩ. Hệ thống cần khả năng phân loại ý định người dùng và truy xuất chính xác nguồn dữ liệu nội bộ.

Phát triển trang quản trị nền tảng Web cho phép đội ngũ tuyển sinh cập nhật trực tiếp văn bản quy định mới, đồng thời giám sát lịch sử hội thoại và chất lượng phản hồi từ hệ thống.

3. Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu là kỹ thuật RAG, tập trung vào việc thiết lập luồng tiền xử lý tài liệu đa định dạng. Hệ thống tích hợp thư viện LangChain để giải xuất các tệp DOCX và áp dụng nền tảng Docling nhằm tái cấu trúc tệp PDF sang định dạng Markdown. Quá trình chia nhỏ văn bản được thực hiện thông qua thuật toán RecursiveCharacterTextSplitter để chuẩn bị dữ liệu đầu vào cho mô hình nhúng. Nền tảng tri thức cốt lõi là tập dữ liệu tuyển sinh chính thức của trường từ năm 2020 đến 2026.

Phạm vi dữ liệu bao gồm 86 tệp tài liệu nguyên thủy (38 tệp đại học, 36 tệp thạc sĩ và 12 tệp tiến sĩ). Khung phần mềm chạy trên Python, điều phối luồng truy xuất bằng FastAPI và lưu trữ embeddings cục bộ qua ChromaDB. Hệ thống từ chối trả lời mọi câu hỏi không thuộc phạm vi tuyển sinh nội bộ.

4. Phương pháp nghiên cứu

Nghiên cứu tài liệu học thuật về AI và hệ thống truy xuất thông tin để xác định thiết kế kiến trúc chuẩn cho toàn bộ quy trình RAG.

Nghiên cứu thực nghiệm được thực hiện để đo lường độ trễ, độ chính xác của các chiến lược phân đoạn văn bản và thuật toán so khớp vector. Kết quả này định hướng lựa chọn cấu hình siêu tham số tối ưu.

Phát triển phần mềm tuân thủ quy trình kiểm thử liên tục, phân tách rõ ràng luồng dữ liệu giữa giao diện nhắn tin, hệ thống máy chủ và khối CSDL.

5. Ý nghĩa khoa học và thực tiễn

Đề tài góp phần hệ thống hóa quy trình xây dựng ứng dụng hỏi đáp dựa trên tri thức chuyên biệt bằng tiếng Việt. Kinh nghiệm thử nghiệm và tinh chỉnh các tham số trên dữ liệu thực tế đóng vai trò quan trọng cho công tác triển khai RAG đối với các tài liệu quy định giáo dục vốn có tính khuôn mẫu và phức tạp cao.

Sản phẩm cung cấp hệ thống tư vấn tự động 24/7, giảm tải khối lượng công việc cho phòng ban tuyển sinh. Trang quản trị hỗ trợ số hóa và giám sát tập trung toàn bộ kho dữ liệu đầu vào, tạo tiền đề cho các dự án chuyển đổi số tiếp theo của nhà trường.

CHƯƠNG 1: CƠ SỞ LÝ THUYẾT VÀ TỔNG QUAN NGHIÊN CỨU

1.1. Tổng quan về trợ lý ảo và bài toán hỏi đáp tự động

Trong giai đoạn đầu ứng dụng thương mại, hệ thống trợ lý ảo chủ yếu hoạt động dựa trên kịch bản cứng. Các lập trình viên phải xây dựng thủ công các cây quyết định phức tạp, định nghĩa từng nhánh hội thoại tương ứng với lựa chọn của người dùng. Mặc dù kiến trúc này dễ kiểm soát và đảm bảo tính chính xác tuyệt đối trong các trường hợp được định nghĩa rõ ràng, kiến trúc này bộc lộ điểm yếu ở khi sử dụng thực tế. Hệ thống rơi vào bế tắc hoặc lặp vòng khi người dùng diễn đạt câu hỏi vượt ngoài luồng hoặc sử dụng từ lóng, biến thể ngôn ngữ mà lập trình viên chưa dự liệu trước.

Xử lý ngôn ngữ tự nhiên truyền thống cải thiện một phần tình trạng này thông qua cơ chế phân loại ý định và nhận diện thực thể. Các hệ thống như Dialogflow hay Rasa cho phép gán nhãn hàng ngàn câu mẫu để huấn luyện mô hình học máy nhận biết ý định người dùng. Giới hạn cốt lõi vẫn tồn tại khi chatbot không tự hiểu ngôn ngữ, mô hình chỉ so khớp xác suất văn bản đầu vào với các nhãn đã định nghĩa, và quan trọng nhất, hệ thống không có khả năng tự động sinh ra một câu trả lời mới mẻ. Phản hồi cuối cùng vẫn là những chuỗi văn bản được soạn sẵn.

Sự bùng nổ của các LLM đánh dấu sự chuyển mình từ so khớp mẫu sang hiểu và sinh ngôn ngữ. Bài toán xử lý hội thoại chuyển sang một giai đoạn mới nhờ khả năng phân tích ngữ cảnh dài, suy luận logic cơ bản và sinh ngôn ngữ tự nhiên như con người.

Dựa trên cơ chế cốt lõi, trợ lý ảo hiện đại được phân thành ba kiến trúc chính:

- Kiến trúc truy xuất thuần túy tập trung tìm kiếm và trả về nguyên văn câu trả lời từ CSDL đóng. Phương pháp này đảm bảo tính an toàn cao nhất nhưng kém linh hoạt, chỉ trả lời được khi câu hỏi trùng khớp cao với dữ liệu mẫu.

- Kiến trúc sinh văn bản tự động tạo phản hồi theo xác suất phân phối từ của LLM, cho phép hội thoại cực kỳ tự nhiên. Kiến trúc này tiềm ẩn rủi ro hiện tượng ảo giác, tức là sinh ra thông tin có vẻ hợp lý nhưng hoàn toàn sai sự thật do không có cơ chế đối chiếu.
- Kiến trúc lai kết hợp hai cơ chế này, sử dụng thông tin truy xuất chính xác từ CSDL nội bộ làm ngữ cảnh nền tảng, sau đó cấp cho LLM để sinh phản hồi tự nhiên và chuẩn xác dựa trên ngữ cảnh đó.

Ứng dụng trợ lý ảo vào công tác tuyển sinh thuộc bài toán hỏi đáp miền tri thức chuyên biệt. Khác với hệ thống tán gẫu đa miền, hệ thống giáo dục đòi hỏi độ chính xác tuyệt đối. Tư vấn sai mã ngành, tổ hợp xét tuyển, hay điểm chuẩn có thể làm lỡ dở cơ hội học tập của thí sinh. Hệ thống bắt buộc phải có cơ sở đối chiếu tri thức nghiêm ngặt, đảm bảo mọi phản hồi được nội suy trực tiếp từ văn bản quy chế chính thống của trường.

1.2. LLM và kiến trúc Transformer

1.2.1. Kiến trúc Transformer và cơ chế tự chú ý

Các LLM hiện đại như GPT-4, Llama 3 hay Google Gemini đều được xây dựng dựa trên kiến trúc Transformer, lần đầu được giới thiệu bởi Vaswani và cộng sự (2017). Khác biệt cốt lõi của Transformer so với các mạng nơ-ron tuần tự truyền thống nằm ở cơ chế tự chú ý.

Thay vì xử lý từng từ một theo thứ tự, cơ chế tự chú ý tính toán song song mối quan hệ giữa tất cả các từ trong một chuỗi văn bản đầu vào. Quá trình này giúp mô hình đánh giá xem từ nào quan trọng hơn để tập trung xử lý khi phân tích một câu hỏi cụ thể. Nhờ tính toán song song ma trận, kiến trúc này giúp mô hình nắm bắt được ngữ cảnh từ khoảng cách cực xa trong văn bản và tăng đáng kể tốc độ huấn luyện do tận dụng tối đa sức mạnh của phần cứng.

1.2.2. Vòng đời huấn luyện của LLM

Để trở thành một trợ lý ảo thực thụ, một LLM phải trải qua ba giai đoạn huấn luyện cốt lõi:

- Tiền huấn luyện diễn ra khi mô hình được nạp một lượng dữ liệu khổng lồ từ Internet, Wikipedia, sách, báo. Mục tiêu của mô hình ở giai đoạn này chỉ đơn giản là dự đoán từ tiếp theo. Nhờ vậy, mô hình học được ngữ pháp, từ vựng và một lượng kiến thức tổng quát khổng lồ của nhân loại.
- Tinh chỉnh theo chỉ thị sử dụng khối lượng lớn dữ liệu hỏi đáp chất lượng cao do con người viết ra để dạy mô hình cách tương tác. Mô hình học cách phản hồi lại một câu lệnh thay vì chỉ viết tiếp văn bản một cách vô định.
- Học tăng cường từ phản hồi con người sử dụng thuật toán tối ưu hóa để thưởng hoặc phạt mô hình dựa trên thang điểm đánh giá của người dân nhân. Giai đoạn này định hình hành vi an toàn, đảm bảo mô hình ưu tiên tính hữu ích, không thiên kiến và từ chối các yêu cầu vi phạm chính sách.

1.2.3. Hạn chế của LLM trong hệ thống tri thức đóng

Khi ứng dụng LLM nguyên bản vào hệ thống tuyển sinh, bài toán đối mặt với ba rào cản kỹ thuật lớn:

- Hiện tượng ảo giác là rủi ro nguy hiểm nhất. Bản chất của LLM là thống kê xác suất, LLM không có khái niệm biết hay không biết. Khi được hỏi về điểm chuẩn ngành Công nghệ thông tin của trường năm nay, nếu chưa từng thấy dữ liệu này, mô hình sẽ sinh ra một con số ngẫu nhiên vì cấu trúc đó hợp lý về mặt ngữ pháp, dù thông tin đó là hoàn toàn bịa đặt.
- Khuyết thiếu tri thức nội bộ khiến kiến thức của mô hình bị đóng băng tại thời điểm quá trình huấn luyện hoàn tất. Mô hình không thể biết các thông báo xét tuyển bổ sung vừa được ban hành. Việc tinh chỉnh lại toàn bộ mạng nơ-ron

hàng trăm tỷ tham số mỗi khi có một thông báo mới là bất khả thi về mặt tài chính và thời gian.

- Giới hạn của số ngữ cảnh quy định số lượng từ tối đa mô hình có thể xử lý trong một lần gọi. Nếu nạp trực tiếp toàn bộ 86 tệp quy chế vào phân lệnh của mỗi lượt hỏi, bộ nhớ ngữ cảnh sẽ bị tràn. Ngay cả với các mô hình hiện đại hỗ trợ cửa sổ lớn, việc nạp quá nhiều văn bản rác sẽ gây nhiễu chú ý và đẩy chi phí lên mức không thể chi trả, kèm theo độ trễ xử lý tính bằng hàng chục giây.

1.3. Kỹ thuật sinh văn bản tăng cường truy xuất

1.3.1. Khái niệm và kiến trúc cốt lõi

Kỹ thuật RAG được công bố lần đầu bởi Patrick Lewis và cộng sự (2020) là giải pháp triệt để nhằm khắc phục hiện tượng ảo giác và hạn chế về dữ liệu tĩnh của LLM. Thay vì buộc mô hình phải ghi nhớ mọi thứ vào các trọng số mạng nơ-ron, RAG tách bạch tri thức ra một CSDL độc lập.

Kiến trúc tổng quát vận hành qua hai giai đoạn chính: giai đoạn lập chỉ mục và giai đoạn truy xuất sinh văn bản.

- Giai đoạn lập chỉ mục diễn ra độc lập, trong đó tài liệu văn bản thô được làm sạch, cắt thành nhiều mảnh nhỏ, sau đó đưa qua một mô hình nhúng để biến đổi thành các vector đa chiều và lưu trữ tại Vector Database. Quá trình này có thể thực hiện định kỳ mỗi khi có tài liệu mới.
- Giai đoạn truy xuất khởi động khi câu hỏi người dùng được mô hình nhúng chuyển đổi thành vector. CSDL sử dụng thuật toán tìm kiếm khoảng cách gần nhất để trích xuất ra các mảnh tài liệu liên quan nhất. Các mảnh tài liệu này được đẩy vào ngữ cảnh cùng với câu hỏi gốc, ép LLM đóng vai trò đọc hiểu để rút trích câu trả lời từ chính đoạn văn bản vừa tìm được.

1.3.2. Tiền xử lý và các chiến lược phân mảnh

Phân mảnh là bước tiền xử lý mang tính quyết định đến độ chính xác của RAG. Nếu mảnh quá lớn, vector sinh ra sẽ bị loãng ngữ nghĩa, chứa nhiều thông tin nhiễu khiến truy xuất không tập trung. Nếu mảnh quá nhỏ, văn bản bị cắt vụn, mất đi bối cảnh khiến mô hình không đủ cơ sở để lập luận.

Một số chiến lược phân mảnh phổ biến được xem xét trong nghiên cứu:

- Phân rã theo kích thước cố định tiên hành cắt tài liệu thành các khối có số lượng ký tự bằng nhau. Phương pháp này nhanh, dễ triển khai nhưng làm gãy đôi các câu hoặc đoạn văn, phá vỡ cấu trúc ngữ nghĩa ngữ pháp.
- Phân rã đệ quy cố gắng giữ lại trọn vẹn đoạn văn và câu thông qua việc kiểm tra các ký tự phân tách. Thuật toán cắt theo đoạn văn trước, nếu đoạn văn vẫn dài hơn giới hạn, thuật toán sẽ đệ quy cắt theo câu, rồi cắt theo khoảng trắng. Phương pháp này cân bằng giữa hiệu suất và việc duy trì tính toàn vẹn của ngữ cảnh.
- Phân rã theo ngữ nghĩa ứng dụng các công cụ nhận diện cấu trúc tiêu đề để cô lập từng nội dung. Nhờ đó, thông tin của điểm khoản 1 và điểm khoản 2 không bị trộn lẫn vào nhau một cách cơ học.

Bảng dưới đây so sánh RAG với các phương pháp tối ưu LLM phổ biến:

Bảng 1.1: So sánh các phương pháp điều khiển LLM

Tiêu chí	Tình hình mô hình	Kỹ thuật RAG	Thiết kế chỉ thị thuần
Chi phí cập nhật tri thức	Rất cao	Rất thấp	Thấp
Khả năng truy xuất nguồn	Không	Có	Không

Yêu cầu phần cứng	Rất cao	Trung bình	Thấp
Đồng bộ dữ liệu	Rất chậm	Tức thời	Bị giới hạn bởi độ dài lệnh

1.4. Vector Database và kỹ thuật nhúng

1.4.1. Không gian vector và độ đo khoảng cách

Kỹ thuật nhúng văn bản sử dụng các mạng nơ-ron chuyên biệt để ánh xạ chuỗi ký tự thành một vector liên tục trong không gian đa chiều. Đặc điểm vi diệu của không gian này là các khái niệm có ngữ nghĩa tương đồng sẽ có tọa độ gần nhau.

Câu hỏi về thời gian thi đánh giá năng lực và lịch thi HSA hoàn toàn không có chung từ khóa, nhưng vector của chúng trong không gian ngữ nghĩa sẽ hội tụ gần nhau. Điều này giúp RAG vượt qua hoàn toàn giới hạn cứng nhắc của thuật toán tìm kiếm truyền thống vốn chỉ dựa trên so khớp từ khóa chính xác.

Quá trình truy xuất dữ liệu yêu cầu đo lường độ tương đồng giữa vector câu hỏi và các vector tài liệu. Độ đo phổ biến và hiệu quả nhất là khoảng cách Cosine, đánh giá góc giữa hai vector thay vì khoảng cách độ lớn của chúng. Giá trị Cosine dao động từ âm 1 đến 1. Giá trị càng tiệm cận 1 cho thấy hai văn bản có ngữ nghĩa càng giống nhau.

1.4.2. Thuật toán tìm kiếm xấp xỉ

Với một CSDL có hàng triệu mảnh văn bản, việc tính toán khoảng cách từ câu hỏi đến toàn bộ các mảnh văn bản sẽ gây nghẽn cổ chai hệ thống. Các Vector Database hiện đại giải quyết bài toán này bằng thuật toán tìm kiếm lân cận gần đúng phân cấp mạng thể giới nhỏ.

Thuật toán xây dựng một cấu trúc đồ thị nhiều lớp. Ở lớp trên cùng, đồ thị rất thưa thớt, chỉ chứa một số ít các đssiểm tựa. Càng xuống lớp dưới, mật độ điểm càng dày

đặc. Quá trình tìm kiếm bắt đầu từ lớp trên cùng, nhanh chóng nhảy các bước dài đến vùng chứa vector gần giống nhất, sau đó đi xuống lớp dưới để tinh chỉnh phạm vi. Cơ chế này giảm độ phức tạp truy xuất xuống mức thời gian logarit, đảm bảo hệ thống phản hồi dưới 50ms ngay cả khi kho dữ liệu lên tới hàng chục Gigabyte.

1.4.3. Đánh giá các hệ quản trị vector

Quá trình truy xuất dữ liệu tiếng Việt yêu cầu mô hình nhúng có năng lực xử lý đa ngôn ngữ xuất sắc. Đề tài chọn mô hình gemini-embedding-2 của Google, sinh ra vector 768 chiều.

Để quản lý các vector này, hệ thống đã tiến hành kiểm thử hiệu năng đssộc lập trước khi lựa chọn. Môi trường đo lường sử dụng vi xử lý Intel Core i7, bộ nhớ 16GB, kết hợp mô phỏng 500 luồng truy vấn đồng thời:

Bảng 1.2: So sánh thông số hệ quản trị Vector Database

Hệ quản trị	Độ trễ đọc P95	Tài nguyên tiêu thụ	Đặc điểm kiến trúc
Bảng Chroma	14 ms	250 MB	Chạy trực tiếp trên tiến trình nội bộ, độ trễ mạng bằng không. Rất phù hợp cho ứng dụng nguyên khối.
Bảng Pinecone	85 ms	Sử dụng dịch vụ đám mây	Gặp trễ mạng lớn khi đặt tại Việt Nam và phụ thuộc bên thứ ba.
Bảng Milvus	22 ms	Hơn 2 GB	Kiến trúc phân tán, chịu tải hàng tỷ vector nhưng quá công kênh để thiết lập cho đồ án quy mô trung bình.

Dựa trên kết quả thực nghiệm, Chroma được lựa chọn nhờ khả năng nhúng trực tiếp vào ứng dụng máy chủ, mang lại độ trễ mạng bằng 0 và đáp ứng dư dả nhu cầu truy xuất của phạm vi đồ án.

1.5. Tổng quan nghiên cứu liên quan

Ứng dụng AI trong giáo dục đã trải qua nhiều thế hệ phát triển. Các hệ thống đời đầu như Pounce (Đại học Bang Georgia) hay Genie (Đại học Deakin) chủ yếu dựa trên cây quyết định và đối sánh mẫu. Kiến trúc này tuy đảm bảo tính kiểm soát nội dung nhưng thiếu đi khả năng mở rộng. Khi số lượng quy chế tăng lên, biểu đồ trạng thái của bot sẽ bùng nổ tổ hợp, gây tắc nghẽn quá trình bảo trì.

Tại Việt Nam, thế hệ chatbot thứ hai tại một số trường đại học bắt đầu tích hợp các mô hình phân loại ý định. Dù cải thiện được khả năng nhận diện ngôn ngữ tự nhiên, hệ thống vẫn phụ thuộc vào việc kỹ sư phải định nghĩa trước toàn bộ tập ý định và câu mẫu phát ngôn. Kiến trúc này bộc lộ lỗ hổng khi đối mặt với các câu hỏi điều kiện chéo phức tạp. Các hệ thống này thiếu đi cơ chế sinh ngôn ngữ thực thụ và không thể xâu chuỗi thông tin từ nhiều đoạn quy chế khác nhau.

Gần đây, kiến trúc RAG bắt đầu được nghiên cứu như một giải pháp thay thế hoàn hảo. Việc áp dụng RAG cho dữ liệu tiếng Việt mang đặc thù hành chính giáo dục vẫn còn khoảng trống lớn. Dữ liệu quy chế thường chứa bảng biểu phức tạp gộp cột và ngôn ngữ pháp lý đan xen với từ lóng của học sinh. Các hệ thống cơ bản thường thất bại ở bước phân mảnh tài liệu, dẫn đến việc cắt ngang bảng điểm chuẩn hoặc nhầm lẫn giữa quy chế của bậc đại học với thạc sĩ.

Đề tài giải quyết trực tiếp khoảng trống này bằng cách xây dựng một luồng tiền xử lý chuyên biệt, tập trung vào việc áp dụng các thư viện số hóa tài liệu mạnh mẽ để bảo toàn định dạng cấu trúc và nhúng siêu dữ liệu ngữ cảnh vào từng mảnh vector. Bằng cách kết hợp sức mạnh tổng hợp ngôn ngữ với CSDL chuyên ngành nội bộ, hệ thống

xóa bỏ sự phụ thuộc vào kịch bản cứng, mở ra khả năng lập luận trên những truy vấn tổ hợp chưa từng xuất hiện trong tập huấn luyện.

1.6. Các công nghệ sử dụng trong đề tài

Để xây dựng một hệ thống quy mô thực tế, đồ án vận dụng chuỗi công nghệ hiện đại được phân tách theo từng lớp chức năng:

- Khung điều phối LangChain đóng vai trò xâu chuỗi linh hoạt quá trình tiền xử lý văn bản, tương tác truy xuất vector và giao tiếp máy chủ LLM.
- Nền tảng Google Gemini xử lý mã hóa vector và sinh văn bản tự nhiên. Giải pháp sử dụng chung hệ sinh thái này tăng tốc độ luân chuyển dữ liệu và tối ưu độ chính xác ngữ nghĩa cho tiếng Việt, tránh được hiện tượng sai lệch không gian vector giữa mô hình nhúng và mô hình sinh.
- CSDL Chroma được thiết lập cục bộ, quản lý toàn bộ cấu trúc chỉ mục vector của văn bản tuyển sinh.
- Máy chủ nền tảng phát triển bằng ngôn ngữ Python kết hợp FastAPI. Cấu trúc xử lý bất đồng bộ đáp ứng hàng trăm luồng truy vấn mạng song song. Giao thức Server-Sent Events (SSE) được ứng dụng để truyền tải tức thời các mảnh văn bản thẳng về thiết bị người dùng thay vì chờ sinh xong toàn bộ câu, giúp cảm giác độ trễ giảm xuống dưới 1 giây.
- Xử lý tài liệu thô dựa trên thư viện BeautifulSoup và hệ thống nhận dạng quang học OCR để làm sạch nguồn dữ liệu nguyên thủy phức tạp, duy trì cấu trúc bảng biểu trước khi đưa vào hàng đợi lập chỉ mục.
- Giao diện người dùng tích hợp trực tiếp lên nền tảng nhắn tin Zalo Bot giúp tiếp cận thí sinh mà không cần cài đặt thêm ứng dụng di động. Phân hệ Web Admin Dashboard được xây dựng dựa trên ngăn xếp web hiện đại React kết nối thông qua giao thức API.

CHƯƠNG 2: PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG

2.1. Phân tích yêu cầu hệ thống

Hệ thống được thiết kế hướng tới hai nhóm người dùng độc lập là người dùng cuối bao gồm học sinh và phụ huynh, cùng với quản trị viên là đội ngũ cán bộ tuyển sinh. Yêu cầu hệ thống được trích xuất từ việc khảo sát thực tế những khó khăn trong công tác tư vấn tuyển sinh truyền thống.

2.1.1. Yêu cầu chức năng

Mã YC	Tên chức năng	Đối tượng	Mô tả chi tiết
F-01	Hỏi đáp tương tác tự nhiên	Người dùng	Hệ thống phải tiếp nhận câu hỏi bằng ngôn ngữ tự nhiên qua Zalo, nhận diện ý định và phản hồi chính xác dựa trên quy chế.
F-02	Xử lý đa luồng hội thoại	Người dùng	Có khả năng duy trì ngữ cảnh của cuộc hội thoại để trả lời các câu hỏi nối tiếp.
F-03	Đăng nhập an toàn	Quản trị viên	Đăng nhập vào Web Admin Dashboard sử dụng mã hóa tiêu chuẩn, có cơ chế phân quyền tài khoản.
F-04	Nạp và quản trị tài liệu tri thức	Quản trị viên	Giao diện cho phép tải lên tệp PDF hoặc DOCX. Hệ thống tự động phân mảnh và nhúng vào Vector Database. Quản trị viên có thể xóa hoặc cập nhật phiên bản quy chế mới.

F-05	Giám sát lịch sử hội thoại	Quản trị viên	Theo dõi các đoạn trò chuyện giữa trợ lý ảo và thí sinh theo thời gian thực để can thiệp nếu câu trả lời chưa thỏa đáng.
F-06	Thống kê số liệu hệ thống	Quản trị viên	Hiển thị biểu đồ lượng câu hỏi theo thời gian, tỷ lệ đánh giá câu trả lời hữu ích, và thời gian trễ trung bình.


2.1.2. Yêu cầu phi chức năng

Về hiệu năng và tốc độ, độ trễ phản hồi tối đa không vượt quá 5 giây cho mỗi câu hỏi trong điều kiện băng thông mạng ổn định để duy trì sự liền mạch của hội thoại. Về khả năng chịu tải, kiến trúc máy chủ xử lý bất đồng bộ phải đáp ứng tối thiểu 200 lượt hỏi đồng thời trong giai đoạn chốt hồ sơ tuyển sinh.

Độ tin cậy và việc chống ảo giác là yếu tố sống còn, hệ thống không được phép tự bịa đặt thông tin. Nếu truy vấn không có trong CSDL, hệ thống bắt buộc phải phản hồi rằng chưa có thông tin về vấn đề này và yêu cầu người dùng liên hệ phòng đào tạo. Về bảo mật, mọi giao tiếp giữa ứng dụng nhắn tin và máy chủ phải qua mã hóa an toàn, đồng thời tệp tin quy chế tải lên phải được quét mã độc tự động trước khi nhúng.

2.2. Đặc tả Use Case và phân tích tương tác

2.2.1. Biểu đồ Use Case tổng quát



Hình 2.1: Biểu đồ Use Case tổng quát của hệ thống

2.2.2. Đặc tả chi tiết luồng cập nhật tri thức

Điều kiện tiên quyết để thực hiện luồng cập nhật tri thức là quản trị viên đã đăng nhập vào bảng điều khiển. Chuỗi sự kiện chính bắt đầu khi quản trị viên chọn mục quản lý tri thức và tải lên tài liệu mới. Hệ thống hiển thị hộp thoại tải tệp, cho phép chọn tệp chứa quy chế xét tuyển năm nay. Quản trị viên đính kèm siêu dữ liệu về năm áp dụng và bậc đào tạo.


Sau đó, hệ thống đẩy tệp vào hàng đợi xử lý. Trình xử lý nền sẽ đọc tệp, chuyển đổi thành định dạng có cấu trúc, cắt thành các mảnh 1000 ký tự. Các mảnh văn bản được

gọi qua giao diện lập trình để tạo vector nhúng và lưu vào CSDL. Cuối cùng, hệ thống thông báo cập nhật tri thức thành công. Trong trường hợp luồng ngoại lệ, nếu định dạng tệp không được hỗ trợ hoặc dung lượng quá lớn, hệ thống báo lỗi và hủy quá trình.

2.3. Thiết kế cấu trúc dữ liệu và CSDL

Mặc dù trọng tâm của hệ thống là Vector Database dùng để lưu trữ các chiều không gian từ vựng, hệ thống vẫn cần một CSDL quan hệ cục bộ để phục vụ phân hệ quản trị.

2.3.1. Sơ đồ ERD




Hình 2.2: Sơ đồ ERD cho phân hệ quản trị CSDL nền

2.3.2. Cấu trúc lưu trữ vector

Trong Vector Database, dữ liệu không lưu theo bảng mà lưu theo bộ sưu tập. Mỗi Points lưu trữ ba thành phần chính. Thành phần thứ nhất là vector 768 chiều đại diện cho tọa độ toán học. Thành phần thứ hai là văn bản gốc giới hạn 1000 ký tự. Thành phần thứ ba là siêu dữ liệu đính kèm thông tin nguồn gốc tài liệu và bậc đào tạo. Việc đính kèm siêu dữ liệu vô cùng quan trọng, giúp hệ thống lọc nhanh chóng trước khi tính toán khoảng cách vector, giảm chi phí truy xuất tới 40 phần trăm khi người dùng hỏi đích danh về hệ thạc sĩ hoặc đại học.

2.4. Thiết kế kiến trúc hệ thống tổng thể

Kiến trúc hệ thống được thiết kế gồm ba tầng độc lập là tầng dữ liệu, tầng dịch vụ và tầng giao diện. Việc tách lớp nghiêm ngặt đảm bảo tính mở rộng, cho phép thay đổi giao diện mà không ảnh hưởng đến thuật toán nhúng vector.




Hình 2.3: Sơ đồ kiến trúc tổng thể ba tầng phân tán

2.5. Phân tích chi tiết luồng xử lý tương tác

Để làm rõ phương thức giao tiếp giữa các tiến trình, hệ thống xây dựng các biểu đồ tuần tự cho các chức năng lõi.

2.5.1. Luồng xử lý câu hỏi người dùng


Quá trình bắt đầu khi máy chủ ứng dụng nhận tin gửi thông báo sự kiện chứa tin nhắn của người dùng về máy chủ hệ thống.



Hình 2.4: Biểu đồ tuần tự quá trình truy xuất và sinh văn bản

2.5.2. Luồng tiền xử lý và cập nhật tri thức

Quy trình tự động hóa thao tác chuyển đổi tài liệu thô thành Vector Database được thiết kế chạy xử lý nền để không chặn luồng hệ thống chính.



SS

Hình 2.5: Sơ đồ luồng cập nhật tài liệu và những tri thức

2.6. Đặc tả giao diện lập trình ứng dụng (API)

Máy chủ cung cấp các giao thức chuẩn cho nền tảng giao diện. Việc giao tiếp tuân thủ định dạng truyền tải đối tượng nhất quán.

Endpoint	Giao thức	Mục đích	Dữ liệu đầu vào	Dữ liệu phản hồi
/api/webhook	POST	Nhận sự kiện tin nhắn từ người dùng	Dữ liệu sự kiện chứa thông điệp	Trả về trạng thái xử lý thành công
/api/auth	POST	Xác thực quản trị viên sinh mã thông báo	Thông tin đăng nhập	Mã thông báo truy cập
/api/docs	POST	Tải tài liệu lên hệ thống lưu trữ vector	Tệp tài liệu và siêu dữ liệu	Trạng thái đang xử lý
/api/logs	GET	Lấy lịch sử đoạn chat giám sát	Tham số giới hạn và độ dài	Danh sách lịch sử giao tiếp

2.7. Thiết kế kỹ thuật định hướng mô hình


Thiết kế chỉ thị cho mô hình AI tập trung vào ba yêu cầu cốt lõi bao gồm tính chính xác, chống Hallucination và văn phong giao tiếp tự nhiên.

Cấu trúc chỉ thị được thiết lập tại lớp điều phối trung tâm, sử dụng kỹ thuật cung cấp mẫu hội thoại kết hợp nhập vai nhân vật. Khung lệnh hướng dẫn mô hình đóng vai trò là chuyên viên tư vấn chính thức, bắt buộc phải trả lời trực tiếp và ngắn gọn dựa hoàn toàn vào các tài liệu ngữ cảnh trích xuất được. Luật cấm đoán nghiêm ngặt ép mô hình từ chối cung cấp dữ liệu nếu hệ thống truy xuất không trả về kết quả liên quan. Hệ thống sẽ trả lời theo khuôn mẫu định trước nếu thông tin không tồn tại, ngăn chặn

hoàn toàn việc sử dụng suy diễn bên ngoài. Khung chỉ thị lắp ráp ngữ cảnh và câu hỏi người dùng thành các khối riêng biệt để ngăn chặn các kịch bản tấn công làm sai lệch chức năng trợ lý ảo.

2.8. Thiết kế giao diện và nền tảng tương tác


Người dùng tương tác thông qua nền tảng nhắn tin đại chúng phổ biến tại Việt Nam. Việc triển khai trực tiếp trên ứng dụng này loại bỏ rào cản tải phần mềm, giúp quá trình tra cứu thông tin diễn ra mượt mà từ thiết bị di động cá nhân, đặc biệt phù hợp với tập khách hàng là học sinh phổ thông trung học.



Hình 2.6: Giao diện tương tác người dùng trên nền tảng nhắn tin

Bộ phận quản trị sử dụng bảng điều khiển trên nền web để điều hành hệ thống. Giao diện trực quan thiết kế theo phong cách hiện đại cho phép theo dõi quá trình phân rã dữ liệu tải lên, thiết lập bộ quét thông tin tự động và thống kê chỉ số máy chủ. Sự phân

tách rạch rời giữa kênh nhấn tin nhẹ nhàng và kênh điều hành chứa bảng biểu phức tạp giúp tối ưu tài nguyên tính toán và trải nghiệm người dùng.




Hình 2.7: Giao diện quản trị tri thức trên Web Admin Dashboard

CHƯƠNG 3: TRIỂN KHAI HỆ THỐNG

3.1. Thiết lập môi trường phát triển

Dự án được phân chia thành các phân hệ độc lập nhằm tối ưu hóa quá trình quản trị và bảo trì mã nguồn. Cấu trúc thư mục ngăn cách rõ ràng giữa tầng cấu hình, nghiệp vụ cốt lõi và giao diện quản trị.



Hình 3.1: Sơ đồ cấu trúc thư mục dự án

Kiến trúc phần mềm sử dụng khối công nghệ lõi bao gồm FastAPI làm máy chủ điều phối luồng mạng, LangChain thiết lập đường ống xử lý thông tin và Vector Database đóng vai trò kho lưu trữ. Việc phát triển theo mô hình nguyên khối phân hệ giúp quản trị viên có thể thay thế LLM khác chỉ bằng cách cấu hình lại tệp môi trường mà không cần can thiệp vào thuật toán truy xuất.

3.2. Triển khai phân hệ quản trị người dùng

Trong quá trình xây dựng hệ thống, an toàn thông tin và bảo mật phân quyền là yếu tố bắt buộc đối với một hệ thống cấp trường. Đề án đã phát triển một User Management Module, độc lập hoàn toàn với luồng tương tác của trợ lý ảo trên ứng dụng nhắn tin.

3.2.1. Cơ chế xác thực và mã hóa

Hệ thống sử dụng CSDL nội bộ để lưu trữ thông tin. Mật khẩu người dùng không bao giờ được lưu dưới dạng văn bản thô. Hàm băm mật khẩu áp dụng thư viện chuẩn với cơ chế sinh Salt tự động. Quá trình đối chiếu mật khẩu đảm bảo chống lại các cuộc Brute-force và Rainbow Table.

Hệ thống sử dụng cơ chế xác thực JWT stateless thay vì sử dụng phiên truyền thống. Khi cán bộ đăng nhập thành công qua cổng xác thực, hệ thống khởi tạo một chuỗi mã chứa định danh người dùng và thời gian hết hạn là 24 giờ. Mọi yêu cầu thao tác dữ liệu từ Web Admin Dashboard lên máy chủ đều phải đính kèm chuỗi mã này. Lớp trung gian chịu trách nhiệm giải mã và xác thực quyền hạn trước khi cho phép hàm logic thực thi.

3.2.2. Quản lý vòng đời tài khoản và lưu vết

Phân hệ cung cấp bộ giao thức kết nối hoàn chỉnh để quản trị viên cấp cao có thể khởi tạo, cập nhật, xóa và truy xuất danh sách nhân sự. Hệ thống tích hợp logic ràng buộc chặn quản trị viên tự xóa chính tài khoản đang đăng nhập của mình để tránh gây lỗi mất quyền kiểm soát toàn cục.

Mọi hành động nhạy cảm như thêm mới tài khoản, đổi mật khẩu hay xóa quyền truy cập đều được hệ thống tự động lưu vết qua Audit Logging tích hợp sẵn. Điều này giúp minh bạch hóa trách nhiệm và dễ dàng truy vết khi có sự cố thay đổi dữ liệu.

3.3. Triển khai phân hệ tự động thu thập dữ liệu

Một trong những thách thức lớn nhất của hệ thống hỏi đáp là việc duy trì sự cập nhật của CSTT. Thay vì ép buộc cán bộ tuyển sinh phải tự tải về từng văn bản thông báo trên trang web của trường rồi tải ngược lên hệ thống, đồ án đã phát triển Web Scraper đóng vai trò như một công cụ tự động hóa quy trình nghiệp vụ.

3.3.1. Kiến trúc luồng thu thập dữ liệu

Công cụ thu thập được lập trình để quét mã nguồn của cổng thông tin tuyển sinh. Phân hệ này bóc tách các bài viết thông báo mới nhất theo từng danh mục định sẵn. Hệ thống duy trì tệp trạng thái để ghi nhớ mốc thời gian cào dữ liệu gần nhất. Khi kích hoạt thông qua cổng lệnh kiểm tra, hệ thống tiến hành đối chiếu và chỉ tải về những thông báo chưa từng xuất hiện.

3.3.2. Xử lý đa luồng và tạo tài liệu động

Để tăng tốc độ quét hàng trăm bài viết, hệ thống sử dụng cơ chế xử lý đa luồng. Việc chạy song song giúp tải các tệp đính kèm như PDF hoặc DOCX cùng một lúc thông qua thư viện kết nối mạng.

Điểm đột phá kỹ thuật nằm ở cơ chế chuyển đổi nội dung web sang định dạng cấu trúc. Nếu bài viết tuyển sinh không có tệp đính kèm mà chỉ có văn bản trực tiếp trên web, hệ thống sẽ dùng công cụ bóc tách để trích xuất văn bản thuần túy và bỏ qua mã rác. Sau đó, hệ thống dùng thư viện xử lý tài liệu để tự động tạo ra một tệp Word mới với tiêu đề chính là tên bài viết, chứa toàn bộ nội dung của bài viết, rồi đẩy tệp này vào luồng tiền xử lý của Vector Database. Nhờ đó, máy chủ có thể đọc hiểu cả các thông báo văn bản ngắc trên web.

3.4. Triển khai phân hệ quản trị kho tri thức và dữ liệu vector

Luồng nghiệp vụ xử lý dữ liệu của đề tài không dừng lại ở việc thiết lập Vector Database, mà bao hàm toàn bộ quy trình kiểm soát trạng thái tệp gốc thông qua mô đun quản lý dữ liệu.

3.4.1. Cơ chế xóa và ghi đè thông minh

Trong bối cảnh văn bản hành chính, một quy chế của năm nay có thể sẽ thay thế hoàn toàn bản quy chế năm trước. Nếu cả hai văn bản cùng tồn tại trong kho lưu trữ, mô hình AI sẽ gặp tình trạng Knowledge Conflict. Giao thức xóa tệp giải quyết triệt để

bài toán này thông qua luồng xóa đồng bộ. Quy trình bắt đầu bằng việc nhận lệnh xóa từ giao diện web, tiến hành xóa tệp vật lý tương ứng trên máy chủ, và kết nối trực tiếp với Vector Database để thanh lọc toàn bộ các Points thuộc về tệp đó. Cơ chế xóa triệt để này đảm bảo dữ liệu máy học và dữ liệu vật lý luôn đồng nhất.

3.4.2. Thống kê và xử lý tệp rác

Cổng thống kê cung cấp cái nhìn toàn cảnh về bộ não nhân tạo, bao gồm tổng số lượng tài liệu vật lý đã tải lên và tổng số mảnh văn bản đã được phân rã thành công. Hệ thống hỗ trợ đường dẫn chuyên dò tìm các tệp không nằm trong danh sách định dạng chuẩn, giúp dọn dẹp không gian lưu trữ rác và các quá trình nhận dạng văn bản thất bại.

3.5. Triển khai cơ chế tối ưu hóa hệ thống

Để đảm bảo khả năng chịu tải và tốc độ phản hồi trong mùa cao điểm tuyển sinh, hệ thống tích hợp ba cơ chế tối ưu hóa cấp độ kiến trúc.

3.5.1. Cơ chế Semantic Cache

Đây là một điểm sáng nhằm giảm thiểu chi phí dịch vụ và triệt tiêu độ trễ mạng. Thay vì gọi dịch vụ AI liên tục cho cùng một câu hỏi, hệ thống xây dựng một bảng nhớ đệm ngữ nghĩa cục bộ.

Khi người dùng hỏi một câu, câu hỏi được nhúng thành vector. Nếu sau đó có người khác hỏi một câu tương tự về mặt ngữ nghĩa, hệ thống không tốn tài nguyên truy xuất lại toàn bộ kho tri thức. Mã nguồn trích xuất các mảng vector từ bảng nhớ đệm, chuyển thành ma trận và sử dụng Dot product và Norm để đo lường độ tương đồng. Nếu điểm số đạt ngưỡng khắt khe, hệ thống trả thẳng kết quả cũ từ máy chủ cục bộ với độ trễ siêu thấp. Vòng đời của bộ nhớ đệm được thiết lập là 30 ngày.

3.5.2. Kiến trúc đa phương thức và cơ chế chống quá tải

Khi ứng dụng nhận hàng ngàn tin nhắn, việc gọi dịch vụ có thể bị từ chối do chạm mốc giới hạn tài nguyên. Lớp MultimodalEngine được bọc bởi thuật toán bẫy lỗi tự động nhận diện tình trạng từ chối dịch vụ. Khi bị từ chối, luồng xử lý không làm treo máy chủ mà sẽ đi vào trạng thái chờ và thực hiện thử lại tối đa 3 lần. Nhờ đó, hệ thống giữ được tính kiên cường cực cao. Mô đun này sử dụng công cụ kết nối mới nhất để tải tệp vật lý trực tiếp lên đám mây, theo dõi vòng đời tệp từ khi xử lý đến khi hoàn tất, và tự động dọn dẹp không gian sau khi thao tác xong.

3.5.3. Cơ chế dự phòng thu thập tin nhắn

Ứng dụng tương tác thường hoạt động qua cơ chế đẩy thông báo trực tiếp. Khi hệ thống bảo trì hoặc chạy trong môi trường không có địa chỉ mạng tĩnh, cơ chế này sẽ vô tác dụng. Đồ án xử lý vấn đề này bằng việc cung cấp một tiến trình nền thực hiện Long Polling. Hàm cập nhật liên tục giữ kết nối mạng đến máy chủ trung gian, kiểm soát con trỏ để đảm bảo không bỏ sót bất kỳ tin nhắn nào của thí sinh, tạo thành lưới an toàn hoàn hảo.

3.6. Triển khai giao diện lập trình ứng dụng

Hệ thống máy chủ đóng vai trò cầu nối điều khiển luồng giao tiếp mạng thông qua thiết kế chuẩn hóa. Tuyến dịch vụ cốt lõi truyền luồng dữ liệu theo định dạng Server-Sent Events (SSE), mang lại Streaming giúp giảm độ trễ hiển thị xuống mức thấp nhất.

Hệ thống hỗ trợ xử lý luồng nhận thông báo để đồng bộ với hạ tầng máy chủ của ứng dụng nhắn tin, kết hợp với CORS Middleware để chấp nhận kết nối đa miền từ Web Admin Dashboard. Bảng điều khiển và tập lệnh trình duyệt được phục vụ thông qua công cụ phát tệp tĩnh tích hợp sẵn.

3.7. Triển khai giao diện quản trị và ứng dụng người dùng

Hệ thống cung cấp hai phương thức tương tác chính: giao diện dành cho người dùng cuối (thí sinh, phụ huynh) và giao diện quản trị tập trung (dành cho ban tuyển sinh).

3.7.1. Giao diện người dùng trên nền tảng nhắn tin


Người dùng tương tác thông qua nền tảng nhắn tin Zalo. Việc triển khai trực tiếp trên ứng dụng nhắn tin loại bỏ rào cản cài đặt phần mềm mới, giúp quá trình tra cứu thông tin diễn ra mượt mà và trực tiếp từ thiết bị di động cá nhân. Mọi thao tác nhắn tin đều tuân thủ thói quen sử dụng thông thường của người dùng.



Hình 3.2: Hệ thống trợ lý ảo đang tư vấn trực tiếp trên nền tảng Zalo

3.7.2. Bảng điều khiển quản trị tổng quan (Dashboard)


Web Admin Dashboard cung cấp một nền tảng quản trị trực quan, hiển thị các thông số thống kê theo thời gian thực về máy chủ, số lượng tài liệu đã mã hóa, cũng như lịch sử tương tác. Tại giao diện này, quản trị viên có thể theo dõi nhanh hiệu suất hoạt động của bộ não nhân tạo.



Hình 3.3: Bảng điều khiển quản trị tổng quan trên Web Admin Dashboard

3.7.3. Phân hệ quản lý tài liệu và mã hóa dữ liệu


Danh sách tài liệu quản lý tập trung phản ánh trạng thái từng tệp bằng mã màu tiêu chuẩn. Giao diện hỗ trợ quản trị viên tải tệp lên (PDF, DOCX) bằng thao tác kéo thả, trực tiếp kích hoạt quá trình bóc tách và giám sát tiến trình mã hóa thành các Vector đa chiều. Các tệp rác hoặc lỗi đều có thể được xóa trực tiếp tại đây.



Hình 3.4: Giao diện quản trị tri thức và tải lên tài liệu

3.7.4. Phân hệ thu thập dữ liệu tự động (Web Scraper)


Giao diện quản lý Scraper cho phép quản trị viên kích hoạt công cụ cào dữ liệu từ trang web tuyển sinh của trường. Giao diện sẽ hiển thị chi tiết tiến trình cào dữ liệu, số lượng bài viết mới được phát hiện và tự động báo cáo kết quả sau khi quy trình bóc tách hoàn tất.



Hình 3.5: Giao diện điều khiển bộ tự động thu thập dữ liệu

3.7.5. Giao diện kiểm thử hệ thống (Chat Tester)


Để đảm bảo độ chính xác trước khi cung cấp dịch vụ ra công chúng, Web Admin cung cấp một công cụ Chat Tester độc lập. Tại đây, quản trị viên có thể nhập câu hỏi để giả lập luồng hội thoại. Hệ thống sẽ trả về câu trả lời cùng với các tham số đo lường thời gian trễ và tài liệu nguồn đã dùng để suy luận.



Hình 3.6: Giao diện kiểm thử trợ lý ảo (Chat Tester) dành cho quản trị viên

3.7.6. Phân hệ quản lý người dùng


Để đảm bảo tính bảo mật của hệ thống, giao diện quản trị cung cấp phân hệ quản lý người dùng. Quản trị viên cấp cao có thể tạo mới, cập nhật, cấp quyền hoặc thu hồi quyền truy cập của các thành viên trong ban tuyển sinh. Các thao tác đều được giám sát và lưu vết để đảm bảo tính minh bạch.



ssHình 3.7: Giao diện phân hệ quản lý người dùng

3.7.7. Giao diện quản lý từ viết tắt


Trong ngữ cảnh tuyển sinh, học sinh thường sử dụng rất nhiều từ lóng hoặc từ viết tắt (VD: "cntt" thay cho "Công nghệ thông tin"). Giao diện này cho phép quản trị viên định nghĩa và cập nhật linh hoạt từ điển viết tắt. Khi câu hỏi đi vào hệ thống, các từ này sẽ được tự động giải nghĩa trước khi đưa vào luồng tìm kiếm.



Hình 3.8: Giao diện quản lý và định nghĩa từ viết tắt

3.7.8. Kiểm thử tiền xử lý (Query Test)

Mô đun Query Test cho phép quản trị viên xem trước cách thức hệ thống tiền xử lý và nhúng (embedding) câu hỏi. Quản trị viên có thể kiểm tra xem câu hỏi có được giải nghĩa đúng từ viết tắt hay không, và danh sách các đoạn văn bản (chunks) nào sẽ được Vector Database truy xuất lên. Điều này giúp tinh chỉnh cơ sở dữ liệu một cách hiệu quả nhất.



Hình 3.9: Giao diện kiểm thử luồng tiền xử lý câu hỏi (Query Test)

CHƯƠNG 4: THỬ NGHIỆM VÀ ĐÁNH GIÁ

4.1. Thiết kế phương pháp đánh giá

Quy trình đánh giá được thiết lập nhằm lượng hóa toàn diện hai khía cạnh của hệ thống bao gồm chất lượng sinh văn bản và hiệu năng máy chủ. Đề tài sử dụng tập dữ liệu chuẩn chứa 1200 cặp câu hỏi và câu trả lời được gán nhãn bán tự động từ 86 văn bản gốc.

4.1.1. Phân loại tập dữ liệu kiểm thử

Ma trận kiểm thử bao gồm năm nhóm tình huống chính. Nhóm đầu tiên là tra cứu trực diện mã ngành, chỉ tiêu và điểm chuẩn. Nhóm thứ hai tập trung vào các truy vấn sử dụng từ viết tắt hoặc ngôn ngữ tự do trên mạng xã hội. Nhóm thứ ba kiểm tra các điều kiện chéo phức hợp với nhiều biến số đầu vào. Nhóm thứ tư đánh giá khả năng phản hồi đối với các câu hỏi nằm ngoài phạm vi tuyển sinh. Nhóm cuối cùng yêu cầu truy xuất thông tin trải dài trên đa bậc đào tạo.

4.1.2. Tiêu chí đánh giá chất lượng sinh

Hệ thống đánh giá chất lượng sinh văn bản dựa trên bốn tiêu chí cốt lõi (Es và cộng sự, 2023). Bốn tiêu chí này bao gồm Context Precision, Context Recall, độ trung thực để chống Hallucination, và cuối cùng là Answer Relevancy.

4.1.3. Kịch bản kiểm thử hiệu năng tối ưu hóa

Bên cạnh bài kiểm tra truy xuất tiêu chuẩn, hệ thống được thử nghiệm chịu tải thông qua hai bài kiểm thử chuyên biệt nhằm đánh giá các cơ chế tối ưu mới được tích hợp. Bài kiểm thử Semantic Cache tiến hành gửi 500 truy vấn lặp lại hoặc có biến thể ngữ nghĩa nhẹ để đo lường tỷ lệ trùng đệm và sự chênh lệch độ trễ. Bài kiểm thử chống quá tải thực hiện gửi dồn dập 2000 luồng truy vấn đồng thời qua cổng kết nối dịch vụ AI để cố tình gây tràn hạn mức, qua đó quan sát khả năng chống sập của hệ thống.

4.2. Kết quả thử nghiệm

4.2.1. Đánh giá độ chính xác

Kết quả trích xuất sau khi chạy kiểm thử trên toàn bộ 1200 câu hỏi:

Bảng 4.1: Kết quả đánh giá hiệu năng trên tập truy vấn

Nhóm câu hỏi	Context Precision	Context Recall	Faithfulness	Answer Relevancy
Nhóm 1: Tra cứu đơn lẻ	0.94	0.98	0.96	0.95
Nhóm 2: Từ lóng viết tắt	0.90	0.92	0.89	0.91
Nhóm 3: Logic phức hợp	0.88	0.85	0.91	0.88
Nhóm 4: Ngoài phạm vi	Không có	Không có	Không có	0.95
Nhóm 5: Đa bậc đào tạo	0.86	0.82	0.89	0.85

Bộ chỉ thị mạnh mẽ giúp hệ thống từ chối cung cấp dữ liệu ngoài luồng đạt tỉ lệ 95 phần trăm. Với nhóm ngôn ngữ mạng xã hội, thuật toán nhúng vector vẫn liên kết thành công văn bản quy chế nhờ chung không gian ngữ nghĩa.

4.2.2. Đánh giá hiệu năng và cơ chế tối ưu hóa

Kết quả bài kiểm thử Semantic Cache mang lại sự đột phá về tốc độ:

Bảng 4.2: Đánh giá hiệu năng của Semantic Cache

Kịch bản	Tỷ lệ trùng đệm	Độ trễ trung bình	Mức tiêu thụ API
Câu hỏi mới hoàn toàn	0%	2400 ms	100%

Câu hỏi tương đồng cao	100%	8 ms	0%
Truy vấn ngẫu nhiên thực tế	~ 62%	950 ms	Tiết kiệm 62% chi phí

Trong bài kiểm thử ép tải kích hoạt mã lỗi hạn mức truy cập, hệ thống không xảy ra hiện tượng treo cứng. Lớp MultimodalEngine kích hoạt cơ chế chờ tự động thành công, đưa các luồng vượt ngưỡng vào trạng thái chờ 30 giây và tiếp tục phục hồi xử lý khi hạn mức được mở lại, duy trì tỷ lệ vận hành thành công đạt trên 99 phần trăm. Cơ chế dự phòng cập nhật liên tục cũng thu thập trọn vẹn tin nhắn mà không bị rớt gói dữ liệu nào.

4.3. Phân tích kết quả và thảo luận

Kết quả thực nghiệm phân tách rõ ràng ranh giới năng lực của kiến trúc đề xuất.

Về điểm sáng kỹ thuật, hệ thống chứng minh độ an toàn cực cao trong việc ngăn chặn hiện tượng ảo giác (Hallucination). Sự kết hợp giữa Semantic Cache và thuật toán thử lại tự động giải quyết triệt để vấn đề thất cổ chai của nền tảng dịch vụ đám mây. Sự kết hợp này biến hệ thống thành một giải pháp hoàn toàn khả thi để triển khai thương mại trong mùa cao điểm.


Về rào cản tồn đọng, hệ thống gặp khó khăn khi xử lý nhóm câu hỏi có logic phức hợp lồng ghép nhiều biến số. Ví dụ đối với câu hỏi xác định mức giảm học phí cho một nam sinh ngành Công nghệ thông tin có chứng chỉ ngoại ngữ và thuộc diện hộ nghèo. Các mệnh đề điều kiện rời rạc nằm ở các văn bản khác nhau thường bị mất bối cảnh khi hệ thống phân rã tài liệu theo kích thước, dẫn đến Context Recall bị giảm.

4.4. Minh họa hoạt động hệ thống

Quy trình giao tiếp giữa học sinh và máy chủ được thực hiện trên ứng dụng nhắn tin nội bộ và giao diện quản lý máy chủ. Trên luồng tương tác, văn bản tư vấn được truyền tải từng cụm từ qua Server-Sent Events (SSE) nhằm triệt tiêu cảm giác chờ đợi của người dùng.



Hình 4.1: Hệ thống trợ lý ảo đang tư vấn trực tiếp trên nền tảng nhắn tin



Hình 4.2: Giao diện nạp dữ liệu tri thức tự động trên Web Admin Dashboard

CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1. Tổng kết kết quả đạt được

Nghiên cứu đã hoàn thiện một luồng xử lý End-to-End RAG có tính thực tiễn cao, khắc phục các giới hạn của LLM tĩnh trong bài toán tư vấn tuyển sinh bằng tiếng Việt. Đồ án không chỉ xây dựng thành công bộ đôi giao diện cho người dùng và quản trị viên mà còn ứng dụng các quy chuẩn công nghệ phần mềm tiên tiến nhất để tối ưu hóa kiến trúc.

Cụ thể, hệ thống đã đạt được các cột mốc kỹ thuật xuất sắc:

- Về RPA (Robotic Process Automation), phân hệ Web Scraper đa luồng giải quyết triệt để rào cản cập nhật tài liệu, tự động chuyển đổi mã nguồn trang web thành không gian vector.
- Về tối ưu hóa tài nguyên, ứng dụng thành công Semantic Cache giúp đẩy tốc độ phản hồi đối với các truy vấn trùng lặp xuống dưới 10ms, tiết kiệm hơn 60 phần trăm chi phí gọi dịch vụ đám mây.
- Về tính kiên cường, Rate Limit Backoff và cơ chế dự phòng của nền tảng nhắn tin đảm bảo hệ thống không bị treo hoặc rớt tin nhắn dưới áp lực truy vấn khổng lồ.
- Về quản trị độc lập, việc xây dựng thành công cơ chế xác thực nội bộ và đồng bộ hóa thao tác xóa dữ liệu vật lý với dữ liệu vector đã giải quyết triệt để hiện tượng Knowledge Conflict.

5.2. Đánh giá mức độ hoàn thành mục tiêu

Hệ thống hoàn thành xuất sắc các mục tiêu đề ra về hiệu năng và chức năng nền tảng.

Bảng 5.1: Đối chiếu kết quả thực hiện so với mục tiêu đề tài

Mục tiêu	Kết quả thực hiện	Đánh giá thực nghiệm
Tích hợp ngôn ngữ tự nhiên	Xây dựng lõi xử lý văn bản, xử lý từ lỏng, tiếng Việt không dấu.	Answer Relevancy vượt mức 90 phần trăm
Tự động hóa tri thức	Phát triển công cụ tự động cào dữ liệu thu thập từ cổng thông tin.	Tiết kiệm 95 phần trăm thời gian nạp tài liệu thủ công
Hạn chế bịa đặt thông tin	Khung chỉ thị nghiêm ngặt ép hệ thống từ chối tư vấn nếu không có trong CSDL.	Đạt độ trung thực 0.89
Đảm bảo tốc độ luồng	Triển khai Semantic Cache và cơ chế Server-Sent Events (SSE).	Trúng đệm giảm trễ còn 8ms, tốc độ luồng dưới 1 giây

5.3. Hạn chế của hệ thống

Bên cạnh các thành tựu tối ưu hóa máy chủ, kiến trúc của hệ thống vẫn bộc lộ một số giới hạn về mặt xử lý ngôn ngữ tự nhiên sâu.

- Về ngữ cảnh rời rạc (Chunking Conflict), khi học sinh đưa ra một hồ sơ chứa nhiều điều kiện rẽ nhánh như điểm số, chứng chỉ, hoặc ưu tiên vùng miền, RecursiveCharacterTextSplitter vô tình cắt đứt sự liên kết giữa các điều khoản. Hệ quả là hệ thống không thể tổng hợp đủ biến số để đưa ra kết luận tư vấn cuối cùng.
- Về kiến trúc đệm đơn bộ, Semantic Cache hiện tại đang lưu trữ trực tiếp trên CSDL máy chủ cục bộ. Dù tốc độ rất nhanh, nhưng nếu ứng dụng triển khai theo mô hình phân tán nhiều máy chủ để cân bằng tải, Local Database sẽ không thể đồng bộ hóa bộ nhớ đệm chéo giữa các máy.

5.4. Hướng phát triển

Đề thương mại hóa và nâng cấp kiến trúc lên quy mô lớn hơn, đề án đề xuất các hướng đi cụ thể.

- Sử dụng kiến trúc GraphRAG. Thay vì chỉ tìm kiếm vector thuần túy, hệ thống sẽ được nâng cấp lên kiến trúc GraphRAG. Việc tích hợp CSDL đồ thị sẽ cung cấp mạng lưới liên kết biểu diễn các mối quan hệ phức tạp, ví dụ như quan hệ ngành Công nghệ thông tin yêu cầu khối A00 và được cộng điểm chứng chỉ tiếng Anh. Kiến trúc này triệt tiêu hoàn toàn điểm mù khi trả lời câu hỏi điều kiện chéo.
- Nâng cấp cơ sở hạ tầng đệm. Chuyển đổi lưu trữ đệm ngữ nghĩa từ cục bộ sang hệ thống máy chủ Redis. Điều này cho phép hệ thống triển khai theo Microservices, nhiều máy trạm có thể dùng chung một siêu bộ nhớ đệm, tối ưu cho bài toán Horizontal Scaling.
- Sử dụng Autonomous Agent Scraper. Phân hệ thu thập hiện tại sử dụng thuật toán phân tích mã tĩnh. Hệ thống sẽ được trang bị Multi-Agent, trong đó AI sẽ tự động học cách điều hướng các cổng thông tin thay đổi cấu trúc mã nguồn liên tục, biến hệ thống thu thập tri thức thành một quy trình hoàn toàn tự trị.

TÀI LIỆU THAM KHẢO

- [1] P. Lewis et al., "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," *NeurIPS*, 2020.
- [2] A. Vaswani et al., "Attention Is All You Need," *NeurIPS*, 2017.
- [3] Y. Gao et al., "Retrieval-Augmented Generation for Large Language Models: A Survey," *arXiv preprint*, 2024.
- [4] J. Devlin et al., "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding," *NAACL*, 2019.
- [5] S. Es et al., "RAGAS: Automated Evaluation of Retrieval Augmented Generation," *arXiv preprint*, 2023.
- [6] LangChain AI, "LangChain Documentation," 2024. [Online]. Available: <https://python.langchain.com>.
- [7] Chroma, "ChromaDB Documentation," 2024. [Online]. Available: <https://docs.trychroma.com>.
- [8] Google, "Google Gemini API Reference," 2024. [Online]. Available: <https://ai.google.dev>.
- [9] Trường Đại học Thủy Lợi, "Đề án tuyển sinh trình độ đại học," 2020-2024. [Online]. Available: <http://tuyensinh.tlu.edu.vn>.
- [10] L. Page and M. Gehlbach, "How an artificially intelligent virtual assistant helps students navigate the road to college," *AERA Open*, vol. 3, no. 4, 2017.