

BỘ GIÁO DỤC VÀ ĐÀO TẠO BỘ NÔNG NGHIỆP VÀ PTNT
TRƯỜNG ĐẠI HỌC THỦY LỢI



CAO MINH HIẾU

HỆ THỐNG AI CHATBOT HỖ TRỢ SINH VIÊN
TRƯỜNG ĐẠI HỌC THỦY LỢI
(TƯ VẤN TRA CỨU THEO SỔ TAY SINH VIÊN VÀ DỮ LIỆU
NỘI BỘ)

ĐỒ ÁN TỐT NGHIỆP

Cao Minh Hiếu

ĐỒ ÁN TỐT NGHIỆP

HÀ NỘI, NĂM 2026

HÀ NỘI, NĂM 2026

BỘ GIÁO DỤC VÀ ĐÀO TẠO BỘ NÔNG NGHIỆP VÀ PTNT
TRƯỜNG ĐẠI HỌC THỦY LỢI

CAO MINH HIẾU

HỆ THỐNG AI CHATBOT HỖ TRỢ SINH VIÊN
TRƯỜNG ĐẠI HỌC THỦY LỢI
(TƯ VẤN TRA CỨU THEO SỔ TAY SINH VIÊN VÀ DỮ LIỆU
NỘI BỘ)

Ngành: Công nghệ thông tin

Mã số: 52480201

NGƯỜI HƯỚNG DẪN 1. ThS. Trương Xuân Nam

HÀ NỘI, NĂM 2026



Họ tên sinh viên: Hệ đào tạo: Chính quy
Lớp: 60TH2 Ngành: Công nghệ thông tin
Khoa: Công nghệ thông tin

1- TÊN ĐỀ TÀI:

**PHÁT TRIỂN HỆ THỐNG AI CHATBOT HỖ TRỢ SINH VIÊN TRƯỜNG
ĐẠI HỌC THỦY LỢI (TƯ VẤN TRA CỨU THEO SỔ TAY SINH VIÊN VÀ DỮ
LIỆU NỘI BỘ)**

2- CÁC TÀI LIỆU CƠ BẢN:

- P. Lewis, E. Perez, A. Piktus, et al., “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks,” *arXiv:2005.11401*, 2020.
<https://arxiv.org/abs/2005.11401>
- V. Karpukhin, B. Oguz, S. Min, et al., “Dense Passage Retrieval for Open-Domain Question Answering,” *arXiv:2004.04906*, 2020.
<https://arxiv.org/abs/2004.04906>
- N. Reimers and I. Gurevych, “Sentence-BERT,” *arXiv:1908.10084*, 2019.
<https://arxiv.org/abs/1908.10084>
- J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, “BERT,” *NAACL*, 2019.
<https://arxiv.org/abs/1810.04805>
- Pinecone, “Vector Database 101 / Documentation,” <https://docs.pinecone.io/>
- LangChain, “LangChain Documentation,” <https://python.langchain.com/docs/>

3- NỘI DUNG CÁC PHẦN THUYẾT MINH VÀ TÍNH TOÁN:

Tỷ lệ %

- Chương 1: Tổng quan đề tài
- Chương 2: Ý tưởng và triển khai
- Chương 3: Tổng quan về RAG (Retrieval-augmented generation)
- Chương 4: Xây dựng hệ thống AI Chatbot hỗ trợ sinh viên trường đại học Thủy Lợi (Tư vấn tra cứu theo sổ tay sinh viên và dữ liệu nội bộ)

- Chương 5: Hạn chế và phương hướng phát triển
- 4- GIÁO VIÊN HƯỚNG DẪN TỪNG PHẦN
Giáo viên hướng dẫn toàn bộ đề án: ThS.Trương Xuân Nam
- 5- NGÀY GIAO NHIỆM VỤ ĐỀ ÁN TỐT NGHIỆP
Ngàythángnăm 2025

Trưởng Bộ môn
(Ký và ghi rõ Họ tên)

Giáo viên hướng dẫn chính
(Ký và ghi rõ Họ tên)

Nhiệm vụ Đề án tốt nghiệp đã được Hội đồng thi tốt nghiệp của Khoa thông qua
Ngày.....tháng.....năm 2026
Chủ tịch Hội đồng
(Ký và ghi rõ Họ tên)

Sinh viên đã hoàn thành và nộp bản Đề án tốt nghiệp cho Hội đồng thi
ngày.....tháng.....năm 2026

Sinh viên làm Đề án tốt nghiệp
(Ký và ghi rõ Họ tên)



TRƯỜNG ĐẠI HỌC THUY LỢI KHOA CÔNG NGHỆ THÔNG TIN

BẢN TÓM TẮT ĐỀ CƯƠNG ĐỒ ÁN TỐT NGHIỆP

TÊN ĐỀ TÀI: HỆ THỐNG AI CHATBOT HỖ TRỢ SINH VIÊN TRƯỜNG ĐẠI HỌC THUY LỢI (TƯ VẤN TRA CỨU THEO SỔ TAY SINH VIÊN VÀ DỮ LIỆU NỘI BỘ)

Sinh viên thực hiện: Cao Minh Hiếu

Lớp: 60TH2

Giáo viên hướng dẫn: ThS. Trương Xuân Nam

TÓM TẮT ĐỀ TÀI

Trong bối cảnh khối lượng tài liệu số ngày càng tăng (quy định, hướng dẫn, tài liệu học tập/đồ án...), việc tra cứu thông tin thủ công theo cách đọc từng file hoặc tìm kiếm theo từ khóa thường mất nhiều thời gian, dễ bỏ sót nội dung và khó tổng hợp câu trả lời chính xác theo ngữ cảnh. Vì vậy, đề tài tập trung xây dựng một chatbot hỏi–đáp trên tài liệu nhằm hỗ trợ người dùng truy vấn nhanh, nhận câu trả lời súc tích và có dẫn chiếu nguồn từ chính nội dung tài liệu.

Đề án đề xuất giải pháp Retrieval-Augmented Generation (RAG): hệ thống tự động đọc các tệp (PDF/DOCX/...) được tải lên trong thư mục Google Drive, thực hiện tiền xử lý, chia nhỏ (chunking), tạo vector embedding và lưu vào kho tìm kiếm (vector store). Khi người dùng đặt câu hỏi, hệ thống truy hồi các đoạn liên quan nhất, sau đó kết hợp với mô hình ngôn ngữ để sinh câu trả lời theo ngữ cảnh, đồng thời hiển thị trích dẫn (nguồn đoạn văn/trang) nhằm tăng tính minh bạch và độ tin cậy. Kết quả mong đợi là một chatbot có khả năng tra cứu tài liệu hiệu quả, giảm thời gian tìm kiếm, nâng cao trải nghiệm người dùng và có thể mở rộng cho nhiều bộ tài liệu khác nhau.

CÁC MỤC TIÊU CHÍNH

- Tìm hiểu tổng quan về Chatbot hỏi–đáp trên tài liệu (Document Q&A) và phương pháp Retrieval-Augmented Generation (RAG), bao gồm: chunking, embedding, vector database và cơ chế truy hồi ngữ cảnh.
- Xây dựng quy trình thu thập và xử lý dữ liệu từ các tệp tài liệu (PDF/DOCX/...), thực hiện chuẩn hóa nội dung, phân đoạn và tạo chỉ mục phục vụ truy vấn.

- Phát triển ứng dụng chatbot cho phép người dùng đặt câu hỏi và nhận câu trả lời dựa trên nội dung tài liệu truy hồi được, kèm trích dẫn nguồn (tên file/trang/đoạn) để tăng độ tin cậy.
- Tích hợp cơ chế quản lý kho tài liệu trên Google Drive (tải lên/đồng bộ/cập nhật), xây dựng giao diện quản trị đơn giản để theo dõi tài liệu, trạng thái index và cấu hình hệ thống.

KẾT QUẢ DỰ KIẾN

- Nắm bắt được kiến thức và quy trình xây dựng hệ thống Chatbot hỏi–đáp trên tài liệu theo hướng Retrieval-Augmented Generation (RAG).
- Xây dựng được pipeline xử lý dữ liệu tài liệu: trích xuất nội dung từ PDF/DOCX, làm sạch, chia đoạn (chunking), tạo embedding và lập chỉ mục trong vector database phục vụ truy vấn.
- Hoàn thiện ứng dụng chatbot hỏi–đáp tài liệu có khả năng trả lời theo ngữ cảnh từ kho tài liệu được cung cấp, đồng thời hiển thị trích dẫn nguồn để người dùng kiểm chứng. Ứng dụng bao gồm các chức năng chính như sau:
 - o Nhận câu hỏi tiếng Việt và trả lời dựa trên nội dung các tài liệu đã được index.
 - o Truy hồi các đoạn văn liên quan nhất (top-k) từ vector database để đưa vào ngữ cảnh cho mô hình sinh câu trả lời.
 - o Hiển thị thông tin nguồn tham chiếu: tên file, trang/đoạn trích (hoặc vị trí chunk) tương ứng với câu trả lời.
 - o Quản lý và đồng bộ tài liệu từ Google Drive: thêm mới/cập nhật/xóa tài liệu và tự động re-index khi có thay đổi.
 - o Ghi nhận lịch sử hội thoại, log truy vấn và đánh giá chất lượng (ví dụ: phản hồi đúng/sai, mức độ hài lòng) để cải tiến hệ thống.
- Xây dựng giao diện quản trị/website đơn giản để quản lý kho tài liệu và theo dõi trạng thái hệ thống (danh sách tài liệu, thời điểm index, dung lượng vector store, thống kê truy vấn).

LỜI CAM ĐOAN

Tác giả xin cam đoan đây là Đồ án tốt nghiệp của bản thân tác giả. Các kết quả trong Đồ án tốt nghiệp này là trung thực, và không sao chép từ bất kỳ một nguồn nào và dưới bất kỳ hình thức nào. Việc tham khảo các nguồn tài liệu (nếu có) đã được thực hiện trích dẫn và ghi nguồn tài liệu tham khảo đúng quy định.

Tác giả ĐATN

Chữ ký

Cao Minh Hiếu

LỜI CẢM ƠN

Em xin trân trọng cảm ơn ThS. Trương Xuân Nam đã tận tình hướng dẫn, định hướng và góp ý trong suốt quá trình thực hiện Đồ án tốt nghiệp. Nhờ sự hướng dẫn chi tiết và những nhận xét kịp thời của thầy, em đã có thể hoàn thiện nội dung nghiên cứu, xây dựng hệ thống và tổng hợp báo cáo một cách đầy đủ, rõ ràng hơn.

Em xin gửi lời cảm ơn đến các thầy cô trong Khoa Công nghệ Thông tin – Trường Đại học Thủy Lợi đã trang bị cho em nền tảng kiến thức chuyên môn, đồng thời tạo điều kiện thuận lợi để em học tập và rèn luyện trong thời gian qua. Những kiến thức và kinh nghiệm tích lũy được là cơ sở quan trọng giúp em triển khai đề tài “Phát triển Chatbot hỏi–đáp tài liệu sử dụng thuật toán RAG”.

Bên cạnh đó, em xin cảm ơn gia đình và bạn bè đã luôn động viên, hỗ trợ tinh thần, tạo điều kiện để em tập trung hoàn thành đồ án đúng tiến độ.

Cuối cùng, em xin kính chúc quý thầy cô sức khỏe và thành công. Em xin trân trọng cảm ơn!

(Sinh viên thực hiện)

Cao Minh Hiếu

DANH MỤC HÌNH ẢNH.....	
DANH MỤC CÁC TỪ VIẾT TẮT VÀ GIẢI THÍCH CÁC THUẬT NGỮ.....	
CHƯƠNG 1 TỔNG QUAN ĐỀ TÀI.....	
1.1 Thực trạng.....	1
1.2 Lý do chọn đề tài.....	2
1.3 Mục tiêu.....	3
1.4 Ý nghĩa của đề tài.....	4
CHƯƠNG 2 Ý TƯỞNG VÀ TRIỂN KHAI.....	
2.1 Ý tưởng.....	6
2.1.1 Khởi xử lý & lập chỉ mục tài liệu (Ingestion/Indexing).....	6
2.1.2 Ứng dụng chatbot hỏi–đáp (User Interface).....	6
2.1.3 Website quản lý & lưu trữ.....	7
2.2 Triển khai.....	7
CHƯƠNG 3 TỔNG QUAN VỀ RAG (RETRIEVAL-AUGMENTED GENERATION).....	
3.1 Tổng quan về RAG (Retrieval-Augmented Generation).....	8
3.2 Xác định bài toán.....	10
3.3 Xây dựng mô hình.....	11
3.3.1 Thu thập dữ liệu.....	11
3.3.2 Xử lý dữ liệu.....	11
CHƯƠNG 4 XÂY DỰNG HỆ THỐNG CHATBOT TRUY VẤN TÀI LIỆU DỰA TRÊN RAG 14	
4.1 Yêu cầu ứng dụng.....	14
4.2 Phân tích & thiết kế.....	14
4.2.1 Yêu cầu phần cứng.....	14
4.2.2 Cách thức hoạt động.....	15
4.2.3 Công cụ và kỹ thuật thực hiện.....	17
4.2.4 Thuật toán với từng tính năng.....	17
4.3 Phân tích thiết kế.....	20
4.3.1 Xác định Usecase.....	20
4.3.2 Biểu đồ Usecase.....	21

4.3.3	Kịch bản Usecase	22
4.3.4	Lớp phân tích	31
4.3.5	Thiết kế cơ sở dữ liệu	38
4.3.6	Thiết kế API	38
4.3.7	Hướng dẫn cài đặt	40
4.3.8	Thiết kế giao diện	49
4.3.9	Đánh giá ứng dụng	55
CHƯƠNG 5 HẠNH CHẾ VÀ PHƯƠNG HƯỚNG PHÁT TRIỂN		
5.1	Hành chế tồn đọng	58
5.2	Phương hướng phát triển	58

Hình 1: Số liệu Stack Overflow 2024 Developer Survey	1
Hình 2: Kiến trúc tổng quan của một hệ thống RAG	9
Hình 3: Biểu đồ Usecase	21
Hình 4: Biểu đồ tuần tự	31
Hình 5: Biểu đồ hoạt động	32
Hình 6: Trang chủ hệ thống	49
Hình 7: Chức năng tìm kiếm	50
Hình 8: Chức năng ghi chú	50
Hình 9: Danh sách Mô hình trong không gian làm việc	51
Hình 10: Danh sách kiến thức trong không gian làm việc	51
Hình 11: Danh sách Prompt trong không gian làm việc	52
Hình 12: Danh sách Tools trong không gian làm việc	52
Hình 13: Các thao tác nhanh của chat	53
Hình 14: Màn hình quản trị người sử dụng	53
Hình 15: Màn hình quản trị đánh giá	54
Hình 16: Màn hình quản trị chức năng	54
Hình 17: Màn hình cài đặt	55
Hình 18: DB Supabase	55

DANH MỤC CÁC TỪ VIẾT TẮT VÀ GIẢI THÍCH CÁC THUẬT NGỮ

RAG Retrieval-Augmented Generation

IDC International Data Corporation


DB Database

CHƯƠNG 1 TỔNG QUAN ĐỀ TÀI

1.1 Thực trạng

Trong những năm gần đây, cùng với quá trình chuyển đổi số, khối lượng dữ liệu văn bản điện tử được tạo ra và lưu trữ trong các tổ chức, doanh nghiệp ngày càng gia tăng nhanh chóng. Theo báo cáo *Data Age 2025* do IDC và Seagate công bố, **lượng dữ liệu số toàn cầu dự kiến đạt khoảng 175 Zettabyte vào năm 2025**, trong đó phần lớn là dữ liệu phi cấu trúc như tài liệu PDF, Word, báo cáo nội bộ, hợp đồng và hướng dẫn nghiệp vụ.

Báo cáo *Stack Overflow Developer Survey 2024* cũng chỉ ra rằng hơn 65% lập trình viên và nhân viên chuyên môn phải tra cứu tài liệu hàng ngày, tuy nhiên chỉ 34% trong số đó sử dụng các công cụ tự động hoá để tìm thông tin trong tài liệu lưu trữ, còn lại chủ yếu tìm kiếm thủ công (Nguồn: *Stack Overflow 2024 Developer Survey*).



Hình 1: Số liệu Stack Overflow 2024 Developer Survey

Tại Việt Nam, báo cáo *Vietnam ICT Index 2022* của Bộ Thông tin và Truyền thông cho thấy mức độ ứng dụng công nghệ thông tin và chuyển đổi số trong các cơ quan, tổ chức và doanh nghiệp đang ngày càng được mở rộng, đặc biệt trong việc số hóa tài liệu và quy trình làm việc. Điều này dẫn đến việc tài liệu nội bộ ngày càng nhiều nhưng phân tán trên các hệ thống lưu trữ khác nhau, phổ biến nhất là các nền tảng lưu trữ đám mây như Google Drive.

Tuy nhiên, nhiều nghiên cứu quốc tế chỉ ra rằng việc truy xuất và tìm kiếm thông tin trong các tài liệu số hiện nay vẫn còn kém hiệu quả. Theo khảo sát được tổng hợp từ báo cáo của McKinsey, nhân viên trung bình dành khoảng 1,8 giờ mỗi ngày chỉ để tìm kiếm và thu thập thông tin phục vụ công việc, tương đương gần một ngày làm việc mỗi tuần. Con số này cho thấy việc tìm kiếm thông tin đang chiếm một tỷ lệ đáng kể trong thời gian làm việc của nhân viên tri thức.

Các nền tảng lưu trữ đám mây như Google Drive, Dropbox đang trở thành lựa chọn phổ biến để quản lý tài liệu. Tuy nhiên, các công cụ tích hợp sẵn trên những nền tảng này chỉ hỗ trợ tìm kiếm theo từ khóa rời rạc, không có khả năng trả lời câu hỏi theo ngữ cảnh nội dung thực của tài liệu.

Điều này gây ra các vấn đề sau:

- Tốn thời gian và công sức tra cứu thông tin khi tài liệu lớn và phân tán;
- Không đảm bảo tính chính xác của kết quả tra cứu khi chỉ dùng tìm kiếm từ khóa đơn thuần;
- Không hỗ trợ đặt câu hỏi tự nhiên như hội thoại, dẫn đến trải nghiệm người dùng kém;
- Không thể trích dẫn nguồn thông tin đáng tin cậy trong quá trình trả lời.

Do đó, nhu cầu phát triển một hệ thống chatbot truy vấn thông minh dựa trên nội dung tài liệu, tích hợp RAG (Retrieval-Augmented Generation) để trả lời câu hỏi người dùng và trích dẫn nguồn là hoàn toàn cần thiết và cấp thiết trong bối cảnh dữ liệu ngày càng tăng trưởng mạnh.

1.2 Lý do chọn đề tài

Như đã trình bày ở mục 1.1, cùng với quá trình chuyển đổi số, khối lượng dữ liệu văn bản điện tử trong các tổ chức và doanh nghiệp ngày càng gia tăng nhanh chóng, đặc biệt là các tài liệu phi cấu trúc như PDF, Word, báo cáo nội bộ và tài liệu hướng dẫn nghiệp vụ. Mặc dù các nền tảng lưu trữ đám mây như Google Drive đã giúp việc lưu trữ và chia sẻ tài liệu trở nên thuận tiện hơn, nhưng việc khai thác và truy xuất tri thức từ các tài liệu này vẫn còn gặp nhiều hạn chế.

Qua tìm hiểu từ các báo cáo nghiên cứu và khảo sát thực tế, tác giả nhận thấy có nhiều nguyên nhân dẫn đến việc tra cứu thông tin trong tài liệu số kém hiệu quả, trong đó có hai nguyên nhân nổi bật. Thứ nhất, dữ liệu tài liệu thường bị phân tán trên nhiều thư mục và nhiều hệ thống lưu trữ khác nhau, trong khi các công cụ tìm kiếm hiện có chủ yếu chỉ hỗ trợ tìm kiếm theo từ khóa đơn giản, không đáp ứng được nhu cầu truy vấn thông tin theo ngữ cảnh. Thứ hai, người dùng không có các công cụ hỗ trợ hỏi – đáp

thông minh, cho phép đặt câu hỏi bằng ngôn ngữ tự nhiên và nhận được câu trả lời tổng hợp, có căn cứ trực tiếp từ nội dung tài liệu.

Để giải quyết vấn đề này, trên thị trường đã xuất hiện một số giải pháp và ứng dụng hỗ trợ truy vấn tài liệu bằng trí tuệ nhân tạo, cho phép người dùng tải tài liệu lên hệ thống và đặt câu hỏi để nhận câu trả lời. Tuy nhiên, hầu hết các giải pháp này chưa được tích hợp trực tiếp với kho dữ liệu cá nhân của người dùng, hoặc chỉ hoạt động trong phạm vi một nền tảng nhất định, chưa tận dụng được các hệ thống lưu trữ đám mây phổ biến như Google Drive. Bên cạnh đó, nhiều công cụ vẫn còn hạn chế trong việc trích dẫn nguồn thông tin rõ ràng, gây khó khăn cho người dùng trong việc kiểm chứng độ chính xác của câu trả lời.

Trước những hạn chế nêu trên, tác giả nhận thấy việc nghiên cứu và xây dựng một ứng dụng chatbot truy vấn thông minh, có khả năng xác thực người dùng thông qua Google, truy xuất dữ liệu trực tiếp từ Google Drive, kết hợp mô hình Retrieval-Augmented Generation (RAG) để trả lời câu hỏi dựa trên nội dung tài liệu thực tế và trích dẫn nguồn rõ ràng, là một hướng tiếp cận phù hợp và có tính ứng dụng cao. Chính vì những lý do đó, tác giả quyết định lựa chọn đề tài này để thực hiện đồ án, nhằm góp phần nâng cao hiệu quả khai thác và sử dụng tri thức từ dữ liệu tài liệu số trong bối cảnh chuyển đổi số hiện nay.

1.3 Mục tiêu

Mục tiêu chính của đề tài là nghiên cứu và xây dựng một hệ thống chatbot truy vấn thông minh, cho phép người dùng đặt câu hỏi bằng ngôn ngữ tự nhiên và nhận được câu trả lời dựa trên nội dung các tài liệu văn bản được lưu trữ trên nền tảng Google Drive. Hệ thống được thiết kế theo mô hình Retrieval-Augmented Generation (RAG), nhằm đảm bảo câu trả lời được sinh ra có căn cứ từ dữ liệu thực tế, đồng thời hạn chế hiện tượng trả lời sai hoặc thiếu chính xác.

Để đạt được mục tiêu chính trên, đề tài hướng tới các mục tiêu cụ thể sau:

- Nghiên cứu cơ sở lý thuyết về chatbot, mô hình ngôn ngữ lớn (Large Language Model) và mô hình Retrieval-Augmented Generation (RAG), làm rõ nguyên lý hoạt động và khả năng ứng dụng của RAG trong bài toán hỏi – đáp dựa trên tài liệu.
- Thiết kế và xây dựng cơ chế xác thực người dùng thông qua tài khoản Google, cho phép hệ thống truy cập hợp lệ vào Google Drive của người dùng nhằm đảm bảo tính bảo mật và quyền riêng tư dữ liệu.

- Xây dựng quy trình thu thập và tiền xử lý dữ liệu từ các tài liệu văn bản phổ biến như PDF và Word, bao gồm trích xuất nội dung, chia nhỏ dữ liệu (chunking) và biểu diễn dữ liệu dưới dạng vector phục vụ cho quá trình truy xuất.
- Triển khai hệ thống truy xuất thông tin dựa trên cơ sở dữ liệu vector, nhằm tìm kiếm các đoạn nội dung liên quan nhất đến câu hỏi của người dùng trong kho tài liệu.
- Tích hợp mô hình ngôn ngữ Gemini để sinh câu trả lời dựa trên các nội dung đã được truy xuất, đảm bảo câu trả lời phù hợp với ngữ cảnh và bám sát dữ liệu gốc.
- Xây dựng giao diện chatbot cho phép người dùng tương tác trực tiếp với hệ thống, đồng thời hiển thị rõ ràng các nguồn tài liệu được sử dụng để tạo câu trả lời, giúp tăng tính minh bạch và độ tin cậy của hệ thống.
- Đánh giá hiệu quả của hệ thống, bao gồm độ chính xác của câu trả lời, khả năng giảm thời gian tra cứu thông tin và trải nghiệm người dùng khi sử dụng chatbot so với phương thức tìm kiếm tài liệu truyền thống.

Thông qua việc đạt được các mục tiêu trên, đề tài hướng tới việc xây dựng một giải pháp có tính ứng dụng cao, hỗ trợ người dùng khai thác hiệu quả tri thức từ dữ liệu tài liệu số, phù hợp với xu hướng phát triển của trí tuệ nhân tạo và chuyển đổi số hiện nay.

1.4 Ý nghĩa của đề tài

Đề tài có ý nghĩa cả về mặt khoa học lẫn mặt thực tiễn, góp phần giải quyết một bài toán đang ngày càng phổ biến trong bối cảnh chuyển đổi số và bùng nổ dữ liệu hiện nay.

Về ý nghĩa khoa học, đề tài góp phần nghiên cứu và làm rõ khả năng ứng dụng mô hình Retrieval-Augmented Generation (RAG) trong bài toán chatbot hỏi – đáp dựa trên dữ liệu văn bản phi cấu trúc. Thông qua việc kết hợp giữa cơ chế truy xuất thông tin từ kho tài liệu và khả năng sinh ngôn ngữ tự nhiên của mô hình ngôn ngữ lớn, đề tài giúp minh họa một hướng tiếp cận hiệu quả nhằm khắc phục hạn chế của các chatbot truyền thống, đặc biệt là hiện tượng sinh câu trả lời không dựa trên dữ liệu thực tế. Kết quả nghiên cứu của đề tài có thể được sử dụng làm tài liệu tham khảo cho các nghiên cứu và ứng dụng liên quan đến xử lý ngôn ngữ tự nhiên, hệ thống hỏi – đáp và trí tuệ nhân tạo trong tương lai.

Về ý nghĩa thực tiễn, hệ thống chatbot được xây dựng trong đề tài có khả năng hỗ trợ người dùng truy xuất và khai thác tri thức từ các tài liệu lưu trữ trên Google Drive một cách nhanh chóng và hiệu quả. Thay vì phải tìm kiếm thủ công qua nhiều tài liệu,

người dùng có thể đặt câu hỏi bằng ngôn ngữ tự nhiên và nhận được câu trả lời tổng hợp, có trích dẫn nguồn rõ ràng. Điều này góp phần giảm thời gian tra cứu thông tin, nâng cao hiệu suất làm việc và hạn chế sai sót trong quá trình sử dụng tài liệu.

Bên cạnh đó, việc tích hợp cơ chế xác thực thông qua Google và khai thác trực tiếp dữ liệu từ kho lưu trữ cá nhân giúp đảm bảo tính bảo mật và quyền riêng tư của người dùng, đồng thời tăng khả năng ứng dụng thực tế của hệ thống trong các tổ chức và doanh nghiệp. Hệ thống có thể được mở rộng để áp dụng trong nhiều lĩnh vực khác nhau như quản lý tri thức nội bộ doanh nghiệp, hỗ trợ học tập – nghiên cứu, hoặc làm nền tảng cho các trợ lý số thông minh trong tương lai.

CHƯƠNG 2 Ý TƯỞNG VÀ TRIỂN KHAI

2.1 Ý tưởng

Xây dựng một hệ thống chatbot hỏi–đáp tài liệu theo hướng Retrieval-Augmented Generation (RAG) nhằm hỗ trợ người dùng tra cứu nhanh thông tin từ bộ tài liệu được cung cấp. Hệ thống gồm 3 thành phần chính:

- Khối xử lý & lập chỉ mục tài liệu (Ingestion/Indexing)
- Ứng dụng chatbot hỏi–đáp (User Interface)
- Khối quản trị & lưu trữ (Admin/Storage) tích hợp Google Drive, Supabase

2.1.1 *Khối xử lý & lập chỉ mục tài liệu (Ingestion/Indexing)*

Khối này có nhiệm vụ tiếp nhận các tài liệu (PDF/DOCX/...) được tải lên trong thư mục Google Drive, sau đó xử lý để biến dữ liệu thô thành “tri thức có thể truy vấn”.

Quy trình thực hiện gồm:

- Đồng bộ tài liệu từ Google Drive theo thư mục cấu hình.
- Trích xuất nội dung từ từng tệp (đọc text, loại bỏ phần nhiễu nếu cần).
- Chia nhỏ nội dung (chunking) theo độ dài phù hợp để tăng chất lượng truy hồi.
- Tạo vector embedding cho từng đoạn văn bản.
- Lưu embedding vào vector database (vector store) kèm metadata (tên file, trang, vị trí đoạn) để phục vụ truy vấn và trích dẫn nguồn.

Kết quả đầu ra của khối này là một kho chỉ mục (vector index) cho phép tìm các đoạn liên quan nhất với câu hỏi của người dùng.

2.1.2 *Ứng dụng chatbot hỏi–đáp (User Interface)*

Ứng dụng chatbot cung cấp giao diện để người dùng nhập câu hỏi và nhận câu trả lời dựa trên nội dung tài liệu đã được lập chỉ mục.

Luồng xử lý chính:

- Người dùng nhập câu hỏi. Hệ thống tạo embedding cho câu hỏi, thực hiện truy hồi top-k đoạn liên quan từ vector store.
- Các đoạn truy hồi được đưa vào ngữ cảnh (context) và kết hợp với mô hình ngôn ngữ để sinh câu trả lời theo hướng bám sát tài liệu.
- Hiển thị trích dẫn nguồn (tên file/trang/đoạn) để người dùng kiểm chứng.

Mục tiêu của ứng dụng là cung cấp câu trả lời nhanh, đúng trọng tâm và có căn cứ từ tài liệu, hạn chế trả lời lan man hoặc sai lệch.

2.1.3 Website quản lý & lưu trữ

Khối này nhằm hỗ trợ quản lý dữ liệu và vận hành hệ thống:

- Quản lý danh sách tài liệu trong thư mục Google Drive (thêm mới/cập nhật/xóa).
- Theo dõi trạng thái lập chỉ mục: số lượng tài liệu, số lượng chunk, thời điểm index gần nhất.
- Cấu hình tham số hệ thống: kích thước chunk, số lượng top-k truy hồi, chế độ hiển thị trích dẫn.
- Lưu lịch sử truy vấn/hội thoại (tùy phạm vi đồ án) phục vụ đánh giá và cải tiến chất lượng.

2.2 Triển khai

Triển khai thực hiện ý tưởng theo lần lượt 4 bước như sau:

Bước 1: Tìm hiểu kiến thức tổng quan về Chatbot hỏi–đáp trên tài liệu (Document Q&A) và phương pháp Retrieval-Augmented Generation (RAG). Nghiên cứu các khái niệm liên quan như: embedding, vector database, truy hồi ngữ nghĩa (semantic search), chunking và kỹ thuật giảm hiện tượng trả lời sai/ảo giác bằng trích dẫn nguồn.

Bước 2: Xây dựng bài toán và bộ dữ liệu đầu vào từ các tệp tài liệu (PDF/DOCX/EXCEL). Thực hiện tiền xử lý dữ liệu: Trích xuất nội dung, làm sạch, chia đoạn (chunk), gắn metadata (tên file, trang/đoạn) và tạo chỉ mục embedding trong kho vector để phục vụ truy vấn.

Bước 3: Phát triển ứng dụng chatbot hỏi–đáp: thiết kế giao diện nhập câu hỏi, xây dựng luồng truy hồi top-k đoạn liên quan từ vector store, kết hợp mô hình ngôn ngữ để sinh câu trả lời theo ngữ cảnh và hiển thị trích dẫn nguồn tương ứng.

Bước 4: Xây dựng chức năng quản trị và đồng bộ tài liệu: tích hợp Google Drive để quản lý/tải lên/cập nhật tài liệu trong thư mục quy định, tự động re-index khi tài liệu thay đổi; đồng thời ghi nhận lịch sử truy vấn và trạng thái hệ thống để phục vụ theo dõi và đánh giá.

CHƯƠNG 3 TỔNG QUAN VỀ RAG (RETRIEVAL-AUGMENTED GENERATION)


3.1 Tổng quan về RAG (Retrieval-Augmented Generation)

Trong lĩnh vực xử lý ngôn ngữ tự nhiên, bài toán hỏi–đáp trên tài liệu (Document Question Answering) tập trung vào việc xác định và trích xuất thông tin liên quan trong kho tài liệu để trả lời câu hỏi của người dùng. Với các bộ tài liệu dài và đa dạng định dạng (PDF, DOCX,...), việc tìm kiếm theo từ khóa truyền thống thường gặp hạn chế do không hiểu được ngữ nghĩa, dễ bỏ sót thông tin hoặc trả về nhiều kết quả không đúng trọng tâm.

RAG (Retrieval-Augmented Generation) là một phương pháp kết hợp giữa truy hồi thông tin (retrieval) và mô hình sinh ngôn ngữ (generation) nhằm cải thiện chất lượng câu trả lời. Thay vì để mô hình ngôn ngữ trả lời thuần túy dựa trên kiến thức đã được học, RAG bổ sung thêm ngữ cảnh lấy trực tiếp từ tài liệu, từ đó giúp câu trả lời bám sát nguồn dữ liệu và giảm hiện tượng trả lời sai lệch.

Một hệ thống RAG thường bao gồm 3 thành phần chính:

- **Xử lý dữ liệu và lập chỉ mục (Document processing & Indexing):** trích xuất nội dung từ tài liệu, chia nhỏ nội dung thành các đoạn (chunk) và lưu trữ kèm theo thông tin nguồn.
- **Truy hồi ngữ cảnh (Retriever):** chuyển câu hỏi thành vector biểu diễn (embedding) và tìm các đoạn tài liệu liên quan nhất trong kho vector (vector database/index).
- **Sinh câu trả lời (Generator):** sử dụng mô hình ngôn ngữ để tạo câu trả lời dựa trên câu hỏi và các đoạn ngữ cảnh đã truy hồi, đồng thời có thể kèm trích dẫn nguồn để người dùng kiểm chứng.



Hình 2: Kiến trúc tổng quan của một hệ thống RAG

Trong ảnh trên là cấu trúc tổng quan của phương pháp Retrieval-Augmented Generation (RAG) trong bài toán hỏi–đáp trên tài liệu. Quy trình RAG thường được chia thành hai giai đoạn: giai đoạn lập chỉ mục tài liệu (Indexing) nhằm chuẩn hóa và lưu trữ tri thức dưới dạng vector để phục vụ truy hồi, và giai đoạn truy vấn – sinh câu trả lời (Querying/Generation) nhằm tìm các đoạn nội dung liên quan nhất rồi dùng chúng làm ngữ cảnh để mô hình ngôn ngữ tạo câu trả lời bám sát tài liệu.

Các thành phần trong hình ảnh:

- Indexing: Giai đoạn chuẩn bị dữ liệu; biến tài liệu thô thành dạng có thể truy hồi theo ngữ nghĩa.
- Documents: Tập tài liệu nguồn (PDF/DOCX/TXT/...) chứa thông tin cần tra cứu.
- Chunking: Chia tài liệu thành các đoạn nhỏ để tăng hiệu quả truy hồi và phù hợp giới hạn ngữ cảnh của mô hình.
- Chunks: Các đoạn văn bản sau khi chia; thường kèm thông tin mô tả như tên file/trang/mục để phục vụ tham chiếu.
- Embedding Model: Mô hình nhúng chuyển văn bản (chunk/query) thành vector embedding biểu diễn ý nghĩa ngữ nghĩa.
- Vectorize: Bước tạo vector embedding từ văn bản bằng Embedding Model.
- Indexing (trong kho vector): Lưu các vector embedding vào kho và tạo cấu trúc chỉ mục để tìm kiếm nhanh.
- Vector Store: Kho lưu trữ embedding (và metadata) phục vụ truy hồi theo độ tương đồng.

- User: Người dùng tương tác với hệ thống bằng cách nhập câu hỏi.
- Query: Câu hỏi/đầu vào truy vấn của người dùng.
- Search: Thực hiện tìm kiếm tương đồng trong Vector Store dựa trên embedding của Query.
- Retrieve: Lấy ra các đoạn liên quan nhất (thường top-k) từ Vector Store.
- Relevant Contexts: Tập các đoạn tài liệu được truy hồi, dùng làm ngữ cảnh cho bước sinh câu trả lời.
- Prompt: Chuỗi đầu vào đưa cho mô hình ngôn ngữ, thường gồm: hướng dẫn + Query + Relevant Contexts.
- LLM: Mô hình ngôn ngữ lớn nhận Prompt và tạo nội dung trả lời.
- Generate: Quá trình sinh câu trả lời dựa trên Query và ngữ cảnh truy hồi.
- Response: Kết quả trả về cho người dùng; bám sát nội dung trong Relevant Contexts nên giảm nguy cơ trả lời sai lệch.

3.2 Xác định bài toán

Để xây dựng chatbot hỏi–đáp dựa trên tài liệu, tác giả xác định bài toán theo hướng hỏi–đáp trên tập văn bản (Document Question Answering) kết hợp phương pháp Retrieval-Augmented Generation (RAG). Hệ thống có nhiệm vụ tiếp nhận câu hỏi của người dùng và tự động truy hồi các đoạn nội dung liên quan trong kho tài liệu, từ đó sinh câu trả lời dựa trên ngữ cảnh truy hồi nhằm đảm bảo câu trả lời bám sát nội dung tài liệu gốc và hạn chế hiện tượng trả lời sai lệch.

Bài toán được mô tả với các thành phần chính như sau:

- Đầu vào:
 - Câu hỏi của người dùng (tiếng Việt).
 - Tập tài liệu tham chiếu (PDF/DOCX/TXT/...) được đưa vào hệ thống (có thể lưu trữ trên Google Drive hoặc kho dữ liệu tương đương).
- Đầu ra:
 - Câu trả lời ngắn gọn, đúng trọng tâm dựa trên nội dung tài liệu.
 - Thông tin trích dẫn nguồn tương ứng (tên file, trang/đoạn hoặc mã đoạn văn bản) để người dùng kiểm chứng.
- Phạm vi bài toán:
 - Hệ thống chỉ trả lời dựa trên nội dung của các tài liệu đã được nạp và lập chỉ mục.
 - Trường hợp không truy hồi được nội dung phù hợp, hệ thống phản hồi bằng thông tin tìm kiếm trên web.
- Đơn vị xử lý và truy hồi:

- Tài liệu được chia thành các đoạn (chunks) để lập chỉ mục và phục vụ truy hồi theo ngữ nghĩa. Khi truy vấn, hệ thống truy hồi top-k đoạn liên quan nhất để đưa vào ngữ cảnh cho mô hình sinh câu trả lời.

3.3 Xây dựng mô hình

3.3.1 Thu thập dữ liệu

Đối với bài toán chatbot hỏi–đáp tài liệu sử dụng phương pháp RAG, dữ liệu đầu vào của hệ thống là tập các tài liệu tham chiếu (corpus) dùng làm nguồn tri thức để trả lời câu hỏi của người dùng. Tác giả tiến hành thu thập và tổng hợp các tài liệu liên quan đến phạm vi chatbot, sau đó chuẩn hóa cách đặt tên và tổ chức thư mục để thuận tiện cho các bước tiền xử lý và lập chỉ mục.

Nguồn dữ liệu thu thập bao gồm:

- Sổ tay sinh viên trường Đại Học Thủy Lợi
- Các loại tài liệu khác có định dạng: Word, pdf và excel

Yêu cầu đối với dữ liệu tài liệu:

- Định dạng: Word, pdf và excel
- Được lưu trữ trong thư mục Google drive để dễ dàng quản lý, cập nhật và đồng bộ dữ liệu.

3.3.2 Xử lý dữ liệu

Sau khi đồng bộ các tài liệu từ Google Drive, hệ thống tiến hành chuẩn hoá và xử lý dữ liệu phù hợp với đầu vào của mô hình Retrieval-Augmented Generation (RAG):

- Dữ liệu đầu vào là tài liệu số, bao gồm:
 - File PDF (.pdf)
 - File Word (.docx)
 - File Excel (.xlsx)
- Mỗi tài liệu sau khi đồng bộ sẽ được lưu thông tin quản lý trong bảng Document, bao gồm:
 - id: định danh tài liệu trong hệ thống
 - name: tên tài liệu
 - source_type: loại tài liệu (pdf/docx/xlsx/...)
 - drive_file_id: định danh file trên Google Drive
 - file_size: dung lượng file
 - created_at, updated_at: thời gian tạo/cập nhật
- Hệ thống thực hiện trích xuất nội dung (text extraction) từ tài liệu:

- Với PDF:
 - Trích xuất nội dung theo trang hoặc theo khối văn bản
 - (Tuỳ triển khai) lưu kèm thông tin trang để phục vụ trích nguồn
- Với Word (.docx):
 - Trích xuất nội dung từ các đoạn (paragraph)
 - (Tuỳ triển khai) trích thêm nội dung trong bảng nếu có
- Với Excel (.xlsx):
 - Trích xuất dữ liệu theo từng sheet
 - Chuyển các ô dữ liệu thành dạng văn bản theo cấu trúc hàng–cột để giữ ngữ nghĩa
 - (Tuỳ triển khai) ưu tiên các vùng có dữ liệu thực, bỏ qua ô trống và sheet không có nội dung
 - (Tuỳ triển khai) có thể gắn kèm thông tin nguồn như: tên sheet, số dòng/cột hoặc vùng dữ liệu để phục vụ trích dẫn
- Sau trích xuất, hệ thống chuẩn hoá văn bản:
 - Loại bỏ khoảng trắng thừa, dòng trống không cần thiết
 - Chuẩn hoá ký tự xuống dòng, đảm bảo encoding UTF-8 và giữ dấu tiếng Việt
 - Giảm nhiễu từ header/footer lặp lại (nếu xuất hiện trong nhiều trang)
 - Với Excel, chuẩn hoá dữ liệu số/ngày tháng về định dạng thống nhất (nếu cần)
- Do mô hình ngôn ngữ có giới hạn độ dài ngữ cảnh, hệ thống chia nhỏ nội dung thành các đoạn (chunking) để phục vụ truy xuất:
 - Mỗi tài liệu được tách thành nhiều “chunk” liên tiếp theo thứ tự xuất hiện
 - Mỗi chunk có các thông tin chính:
 - content: nội dung đoạn văn bản
 - chunk_index: số thứ tự chunk trong tài liệu
 - metadata: thông tin nguồn (ví dụ: tên tài liệu, id tài liệu, trang/section; riêng Excel có thể gồm tên sheet, vùng dữ liệu)
 - (Tuỳ cấu hình) sử dụng cơ chế chồng lấn (overlap) giữa các chunk để tránh mất ngữ cảnh ở ranh giới đoạn

Ta thấy nếu tài liệu không được chia nhỏ hợp lý, hệ thống dễ truy xuất thiếu ngữ cảnh (chunk quá ngắn) hoặc truy xuất kém chính xác/giảm hiệu năng (chunk quá dài). Vì vậy bước chunking cần được thiết kế phù hợp để tăng khả năng truy xuất đúng đoạn liên quan và cải thiện chất lượng câu trả lời.

Sau khi tạo chunk, hệ thống thực hiện chuyển đổi văn bản sang vector embedding để phục vụ tìm kiếm theo độ tương đồng:

- Hệ thống sử dụng mô hình embedding của Google:
 - Tên mô hình: models/text-embedding-004
 - Mục đích: biểu diễn mỗi chunk dưới dạng một vector số (embedding vector)
- Thiết lập embedding theo ngữ cảnh sử dụng:
 - Với chunk của tài liệu:
 - task_type = "retrieval_document"
 - Với câu hỏi người dùng:
 - task_type = "retrieval_query"
- Kết quả embedding và dữ liệu chunk được lưu vào bảng Document_chunk, bao gồm:
 - id: định danh chunk
 - document_id: khoá ngoại trỏ tới Document(id)
 - content: nội dung chunk
 - embedding: vector embedding của chunk
 - chunk_index: số thứ tự chunk
 - metadata: thông tin nguồn phục vụ trích dẫn
 - created_at: thời gian tạo bản ghi
- Ràng buộc tham chiếu:
 - Document (id) → Document_chunk (document_id)
 - Quan hệ 1–N (một tài liệu có nhiều chunk)

Khi người dùng đặt câu hỏi, hệ thống tạo embedding cho câu hỏi, truy xuất top-k chunk gần nhất trong cơ sở dữ liệu vector, sau đó đưa các chunk này làm “ngữ cảnh” để mô hình ngôn ngữ lớn Gemini 2.5 Flash sinh câu trả lời. Đồng thời, hệ thống có thể hiển thị nguồn tham khảo dựa trên metadata (tên tài liệu/đoạn liên quan; với Excel là tên sheet/vùng dữ liệu), giúp tăng tính minh bạch và độ tin cậy của kết quả.

CHƯƠNG 4 XÂY DỰNG HỆ THỐNG AI CHATBOT HỖ TRỢ SINH VIÊN TRƯỜNG ĐẠI HỌC THỦY LỢI (TƯ VẤN TRA CỨU THEO SỔ TAY SINH VIÊN VÀ DỮ LIỆU NỘI BỘ)

4.1 Yêu cầu ứng dụng

Tổng quan: Hệ thống chatbot được xây dựng nhằm hỗ trợ người dùng truy vấn và khai thác nội dung từ các tài liệu văn bản lưu trữ trên Google Drive thông qua mô hình Retrieval-Augmented Generation (RAG). Để hệ thống có thể hoạt động ổn định, chính xác và phát huy đầy đủ các chức năng, môi trường triển khai cần đáp ứng một số yêu cầu nhất định về tài khoản dịch vụ, phần mềm và phần cứng.

Các chức năng chính:

- Đăng ký tài khoản người dùng.
- Đăng nhập hệ thống.
- Đăng xuất khỏi hệ thống.
- Tạo hội thoại mới (New chat).
- Nhập câu hỏi/prompt và nhận câu trả lời từ chatbot.
- Tìm kiếm hội thoại theo từ khóa.
- Đổi tên hội thoại.
- Lưu trữ hội thoại (lưu lịch sử chat).
- Xóa hội thoại.
- Chia sẻ hội thoại.
- Tải xuống hội thoại.
- Tải tệp tài liệu lên Google Drive (đưa tài liệu vào kho dữ liệu để chatbot truy vấn).
- Đồng bộ/cập nhật tài liệu từ Google Drive về hệ thống.

4.2 Phân tích & thiết kế

4.2.1 Yêu cầu phần cứng

Thiết bị và môi trường triển khai hệ thống cần đáp ứng đầy đủ các yêu cầu sau:

Yêu cầu về tài khoản và dịch vụ:

- Có tài khoản Google để:
 - Thiết lập Google Cloud Project
 - Cấu hình OAuth 2.0
 - Truy cập Google Drive API
- Có tài khoản Gemini để sử dụng mô hình ngôn ngữ lớn phục vụ sinh câu trả lời

- Có tài khoản Supabase để lưu trữ:
 - Vector embedding
 - Metadata tài liệu
 - Thông tin phục vụ truy xuất và trích dẫn nguồn

Yêu cầu về thiết bị và hệ điều hành:

- Máy tính cá nhân chạy hệ điều hành Windows
- Đã cài đặt:
 - Docker (phục vụ triển khai các service)
 - Python phiên bản từ 3.10 trở lên
- Bộ nhớ trống tối thiểu: 20GB
- Dung lượng lưu trữ còn trống trên Google Drive tối thiểu: 2GB
- Bộ nhớ RAM tối thiểu: 4GB

Những yêu cầu trên đảm bảo hệ thống có đủ tài nguyên để thực hiện các tác vụ như đồng bộ dữ liệu, xử lý tài liệu, sinh embedding và truy vấn dữ liệu trong quá trình vận hành.

Chọn thiết bị demo đáp ứng đầy đủ yêu cầu phần cứng như trên

4.2.2 Cách thức hoạt động

Hệ thống chatbot hoạt động theo mô hình truy vấn kết hợp giữa truy xuất dữ liệu và sinh ngôn ngữ tự nhiên, trong đó dữ liệu đầu vào được lấy trực tiếp từ Google Drive của người dùng. Toàn bộ quá trình được thiết kế nhằm đảm bảo câu trả lời luôn bám sát nội dung tài liệu thực tế và có thể trích dẫn rõ ràng nguồn gốc thông tin.

Quy trình hoạt động của hệ thống bao gồm hai giai đoạn chính:

- Kích hoạt thủ công
 - Giai đoạn đồng bộ và xử lý dữ liệu từ Google Drive
 - Giai đoạn truy vấn và sinh câu trả lời

(Kích hoạt: người dùng nhập thông tin prompt và đẩy file mới lên trên Google Drive để có dữ liệu, sau đó call API đồng bộ)

4.2.2.1 Giai đoạn đồng bộ và xử lý dữ liệu từ *Google Drive*

Khi người dùng tải hoặc cập nhật tài liệu lên Google Drive, hệ thống sẽ thực hiện các bước sau:

- **Xác thực người dùng:** Người dùng đăng nhập hệ thống thông qua tài khoản Google. Hệ thống sử dụng cơ chế OAuth 2.0 để cấp quyền truy cập hợp lệ vào Google Drive, đảm bảo an toàn và quyền riêng tư dữ liệu.
- **Đồng bộ dữ liệu (Sync Data):** Sau khi xác thực thành công, hệ thống tiến hành quét và đồng bộ các tài liệu được hỗ trợ (PDF, Word, Excel) từ Google Drive về hệ thống xử lý trung gian.
- **Trích xuất nội dung tài liệu:** Nội dung văn bản trong các file được trích xuất và chuẩn hóa về định dạng văn bản thuần để phục vụ cho các bước xử lý tiếp theo.
- **Chia nhỏ dữ liệu (Chunking):** Nội dung tài liệu được chia thành các đoạn nhỏ (chunk) với kích thước phù hợp. Mỗi đoạn chunk sẽ đi kèm metadata như:
 - Tên file gốc
 - Vị trí hoặc thứ tự đoạn trong tài liệu
- **Sinh vector embedding và lưu trữ:** Các đoạn chunk được chuyển đổi thành vector embedding và lưu trữ trong cơ sở dữ liệu vector trên Supabase. Metadata được lưu kèm để phục vụ việc truy xuất và trích dẫn nguồn khi trả lời câu hỏi.

Quá trình này được thực hiện tự động mỗi khi có thay đổi dữ liệu trên Google Drive, đảm bảo hệ thống luôn sử dụng phiên bản tài liệu mới nhất.

4.2.2.2 Giai đoạn truy vấn và sinh câu trả lời

Khi người dùng nhập câu hỏi (prompt) vào giao diện chatbot, hệ thống tiến hành các bước sau:

- **Tiếp nhận câu hỏi người dùng:** Câu hỏi được xử lý và chuyển đổi sang dạng embedding để phục vụ truy vấn.
- **Truy xuất dữ liệu liên quan:** Hệ thống thực hiện tìm kiếm trên cơ sở dữ liệu vector để xác định các đoạn nội dung (chunk) có mức độ liên quan cao nhất đến câu hỏi.
- **Sinh câu trả lời bằng mô hình Gemini:** Các đoạn nội dung được truy xuất sẽ được đưa vào mô hình Gemini làm ngữ cảnh. Dựa trên đó, mô hình sinh ra câu trả lời phù hợp với câu hỏi của người dùng.

- **Trích dẫn nguồn thông tin:** Sau khi sinh câu trả lời, hệ thống tổng hợp metadata của các đoạn nội dung đã sử dụng và hiển thị danh sách tài liệu nguồn kèm theo, giúp người dùng biết rõ thông tin được trích xuất từ đâu.

Kết quả cuối cùng được hiển thị dưới dạng hội thoại, bao gồm nội dung trả lời và danh sách nguồn tham khảo, đúng với mục tiêu xây dựng một chatbot truy vấn minh bạch và có căn cứ dữ liệu.

4.2.3 Công cụ và kỹ thuật thực hiện

4.2.3.1 Công cụ, thiết bị và ngôn ngữ lập trình

Trong quá trình xây dựng hệ thống chatbot truy vấn tài liệu, đề tài sử dụng các công cụ và nền tảng chính sau:

- **Google Gemini API:** Được sử dụng làm mô hình ngôn ngữ lớn (LLM) để sinh câu trả lời dựa trên ngữ cảnh truy xuất từ dữ liệu tài liệu. Gemini có khả năng xử lý ngôn ngữ tự nhiên mạnh mẽ và tích hợp tốt với hệ sinh thái Google.
- **Google Drive API:** Được sử dụng để truy cập, đồng bộ và quản lý các tài liệu của người dùng sau khi được xác thực thông qua OAuth 2.0.
- **Supabase:** Được sử dụng làm nền tảng backend lưu trữ:
 - Vector embedding của các đoạn tài liệu
 - Metadata phục vụ truy xuất và trích dẫn nguồn
 - Thông tin quản lý dữ liệu của hệ thống
- **Docker:** Được sử dụng để đóng gói và triển khai các thành phần của hệ thống dưới dạng container, giúp đảm bảo tính nhất quán của môi trường chạy.
- **Python:** Là ngôn ngữ lập trình chính, được sử dụng để:
 - Xử lý tài liệu
 - Thực hiện chunking
 - Sinh embedding
 - Triển khai logic truy vấn RAG

4.2.3.2 Các thư viện và kỹ thuật sử dụng

Hệ thống sử dụng các kỹ thuật và thư viện phổ biến trong lĩnh vực xử lý ngôn ngữ tự nhiên và trí tuệ nhân tạo, bao gồm:

- Trích xuất văn bản từ PDF, Word
- Kỹ thuật chunking để chia nhỏ nội dung tài liệu
- Kỹ thuật vector embedding để biểu diễn ngữ nghĩa văn bản
- Vector similarity search để truy xuất nội dung liên quan

- Kỹ thuật prompt engineering nhằm đảm bảo mô hình Gemini chỉ trả lời dựa trên ngữ cảnh được cung cấp

4.2.4 Thuật toán với từng tính năng

4.2.4.1 Thuật toán đồng bộ dữ liệu từ Google Drive

Thuật toán đồng bộ dữ liệu được thiết kế nhằm đảm bảo hệ thống luôn sử dụng **phiên bản mới nhất của tài liệu**, đồng thời tránh xử lý trùng lặp gây lãng phí tài nguyên.

Giả sử tập các tài liệu trên Google Drive của người dùng là:

$$D = d_1, d_2, \dots, d_n \quad (1)$$

Với mỗi tài liệu d_i , hệ thống lưu trữ metadata gồm:

- file_id
- last_modified_time

Thuật toán đồng bộ được thực hiện như sau:

1. Lấy danh sách file hiện tại từ Google Drive.
2. Với mỗi file d_i , so sánh last_modified_time với dữ liệu đã lưu trong hệ thống.
3. Nếu file là mới hoặc đã được cập nhật, hệ thống tiến hành xử lý lại file đó.
4. Nếu file không thay đổi, bỏ qua để tiết kiệm tài nguyên.

Cách tiếp cận này giúp giảm khối lượng xử lý cho các lần đồng bộ tiếp theo do hệ thống chỉ xử lý trên tập tài liệu thay đổi, thay vì xử lý lại toàn bộ tập tài liệu D .

4.2.4.2 Thuật toán trích xuất và chia nhỏ dữ liệu (Chunking)

Sau khi trích xuất nội dung văn bản từ tài liệu PDF hoặc Word, văn bản được chia thành các đoạn nhỏ (chunk) nhằm phục vụ cho việc sinh embedding và truy xuất thông tin.

Giả sử nội dung tài liệu sau khi trích xuất là chuỗi văn bản:

$$T = w_1, w_2, \dots, w_m \quad (2)$$

Văn bản được chia thành các chunk có kích thước cố định k từ (token):

$$C_j = w_{(j-1)k+1}, \dots, w_{jk} \quad (3)$$

Trong đó:

- k được lựa chọn sao cho đảm bảo đủ ngữ cảnh (thường từ 300–500 token)
- Các chunk có thể chồng lấn một phần (overlap) để tránh mất ngữ nghĩa ở ranh giới đoạn

Mỗi chunk C_j được gắn metadata gồm:

- Tên file gốc
- Thứ tự đoạn trong tài liệu
- Vị trí tương đối trong văn bản

4.2.4.3 Thuật toán sinh vector embedding

Mỗi đoạn chunk C_j được ánh xạ sang một vector embedding trong không gian R^d thông qua mô hình embedding:

$$v_q = f_{\text{embed}}(q) \quad (4)$$

Trong đó:

- f_{embed} là hàm sinh embedding
- d là số chiều của vector embedding

Toàn bộ các vector embedding cùng metadata được lưu trữ trong cơ sở dữ liệu vector. Việc biểu diễn dữ liệu dưới dạng vector cho phép hệ thống đo lường độ tương đồng ngữ nghĩa giữa các đoạn văn bản.

4.2.4.4 Thuật toán truy xuất thông tin (Retrieval)

Khi người dùng nhập câu hỏi q , hệ thống thực hiện các bước sau:

- Chuyển câu hỏi thành vector embedding:

$$v_q = f_{\text{embed}}(q) \quad (5)$$

- Tính độ tương đồng giữa vector câu hỏi và các vector chunk bằng **Cosine Similarity**:

$$\text{sim}(v_q, v_j) = \frac{v_q \cdot v_j}{|v_q||v_j|} \quad (6)$$

- Sắp xếp các chunk theo độ tương đồng giảm dần và chọn ra top-k chunk liên quan nhất:

$$R = \{C_{j_1}, C_{j_2}, \dots, C_{j_k}\} \quad (7)$$

Các chunk trong tập R được xem là ngữ cảnh liên quan nhất để trả lời câu hỏi của người dùng.

4.3 Phân tích thiết kế

4.3.1 Xác định Usecase

Dựa trên yêu cầu chức năng, các use case chính của hệ thống website được xác định như sau:

Nhóm xác thực và tài khoản

- Đăng ký
- Đăng nhập
- Đăng xuất


Nhóm chatbot và hội thoại

- Tạo hội thoại mới (New Chat)
- Nhập prompt câu hỏi
- Tìm kiếm hội thoại
- Đổi tên hội thoại
- Lưu trữ hội thoại
- Xóa hội thoại
- Chia sẻ hội thoại
- Tải xuống hội thoại

Nhóm quản lý dữ liệu

- Đồng bộ tài liệu từ Google Drive
- Tải file lên Google Drive
- Cập nhật dữ liệu tài liệu
- Quản lý trạng thái index dữ liệu

4.3.2 Biểu đồ Usecase



Hình 3: Biểu đồ Usecase

4.3.3 Kịch bản Usecase

4.3.3.1 Đăng ký

Mục	Nội dung
Tên use case	Đăng ký
Tác nhân chính	User
Người chịu trách nhiệm	User
Tiền điều kiện	User đã truy cập website
Đảm bảo tối thiểu	Hiện thị giao diện đăng ký
Đảm bảo thành công	Tài khoản được tạo thành công
Kích hoạt	Click chọn chức năng đăng ký
Chuỗi sự kiện chính	1. Hệ thống hiển thị form đăng ký 2. User nhập thông tin tài khoản 3. Nhấn nút đăng ký 4. Hệ thống kiểm tra dữ liệu hợp lệ 5. Hệ thống tạo tài khoản mới 6. Thông báo đăng ký thành công
Ngoại lệ	1. Thông tin không hợp lệ 1.a. Hệ thống thông báo lỗi 1.b. User nhập lại thông tin

4.3.3.2 Đăng nhập

Mục	Nội dung
Tên use case	Đăng nhập
Tác nhân chính	User
Người chịu trách nhiệm	User
Tiền điều kiện	Đã truy cập website
Đảm bảo tối thiểu	Quay lại giao diện đăng nhập
Đảm bảo thành công	Đăng nhập vào hệ thống
Kích hoạt	Click chọn chức năng đăng nhập
Chuỗi sự kiện chính	1. Hệ thống hiển thị form đăng nhập 2. Nhập tên tài khoản & mật khẩu 3. Nhấn nút đăng nhập 4. Hệ thống kiểm tra thông tin hợp lệ 5. Thông báo đăng nhập thành công 6. Hiển thị trang chủ
Ngoại lệ	1. Sai tài khoản hoặc mật khẩu 1.a. Hệ thống yêu cầu nhập lại

4.3.3.3 Đăng xuất

Mục	Nội dung
Tên use case	Đăng xuất
Tác nhân chính	User
Người chịu trách nhiệm	User
Tiền điều kiện	User đã đăng nhập
Đảm bảo tối thiểu	Quay về trang đăng nhập
Đảm bảo thành công	Phiên đăng nhập kết thúc
Kích hoạt	Click nút đăng xuất
Chuỗi sự kiện chính	1. User chọn đăng xuất 2. Hệ thống xóa session 3. Chuyển về màn hình đăng nhập
Ngoại lệ	Không

4.3.3.4 Tạo hội thoại mới (New Chat)

Mục	Nội dung
Tên use case	Tạo hội thoại mới
Tác nhân chính	User
Người chịu trách nhiệm	User
Tiền điều kiện	User đã đăng nhập
Đảm bảo tối thiểu	Hiển thị khung chat trống
Đảm bảo thành công	Hội thoại mới được tạo
Kích hoạt	Click nút New Chat
Chuỗi sự kiện chính	1. User chọn New Chat 2. Hệ thống tạo phiên chat mới 3. Hiển thị giao diện chat
Ngoại lệ	Không

4.3.3.5 Nhập prompt câu hỏi

Mục	Nội dung
Tên use case	Nhập prompt câu hỏi
Tác nhân chính	User
Người chịu trách nhiệm	User
Tiền điều kiện	Đã có hội thoại
Đảm bảo tối thiểu	Hiển thị câu hỏi
Đảm bảo thành công	Hiển thị câu trả lời
Kích hoạt	Nhập câu hỏi và nhấn gửi
Chuỗi sự kiện chính	1. User nhập câu hỏi 2. Hệ thống gửi truy vấn RAG 3. Truy xuất dữ liệu 4. Sinh câu trả lời 5. Hiển thị kết quả
Ngoại lệ	1. Không tìm thấy dữ liệu phù hợp

4.3.3.6 Tìm kiếm hội thoại

Mục	Nội dung
Tên use case	Tìm kiếm hội thoại
Tác nhân chính	User
Người chịu trách nhiệm	User
Tiền điều kiện	Có lịch sử hội thoại
Đảm bảo tối thiểu	Hiển thị danh sách chat
Đảm bảo thành công	Hiển thị chat phù hợp
Kích hoạt	Nhập từ khóa tìm kiếm
Chuỗi sự kiện chính	1. User nhập từ khóa 2. Hệ thống lọc hội thoại 3. Hiển thị kết quả
Ngoại lệ	Không có kết quả phù hợp

4.3.3.7 Đổi tên hội thoại

Mục	Nội dung
Tên use case	Đổi tên hội thoại
Tác nhân chính	User
Tiền điều kiện	Có hội thoại tồn tại
Đảm bảo thành công	Tên hội thoại được cập nhật
Chuỗi sự kiện chính	1. User chọn đổi tên 2. Nhập tên mới 3. Hệ thống lưu thay đổi

4.3.3.8 Lưu trữ hội thoại

Mục	Nội dung
Tên use case	Lưu trữ hội thoại
Tác nhân chính	User
Tiền điều kiện	Có hội thoại
Đảm bảo thành công	Hội thoại được lưu trữ
Chuỗi sự kiện chính	1. User chọn lưu trữ 2. Hệ thống cập nhật trạng thái

4.3.3.9 Xóa hội thoại

Mục	Nội dung
Tên use case	Xóa hội thoại
Tác nhân chính	User
Tiền điều kiện	Có hội thoại

Đảm bảo thành công	Hội thoại bị xóa
Chuỗi sự kiện chính	1. User chọn xóa 2. Hệ thống yêu cầu xác nhận 3. Xóa hội thoại


4.3.3.10 Chia sẻ hội thoại

Mục	Nội dung
Tên use case	Chia sẻ hội thoại
Tác nhân chính	User
Đảm bảo thành công	Link chia sẻ được tạo
Chuỗi sự kiện chính	1. User chọn chia sẻ 2. Hệ thống tạo link

4.3.3.11 Tải xuống hội thoại

Mục	Nội dung
Tên use case	Tải xuống hội thoại
Tác nhân chính	User
Đảm bảo thành công	File hội thoại được tải
Chuỗi sự kiện chính	1. User chọn tải xuống 2. Hệ thống xuất file

4.3.5 Biểu đồ hoạt động



Hình 5: Biểu đồ hoạt động

4.3.6 Lớp phân tích

4.3.6.1 Xác định các thực thể

- Entity_Document
- Entity_DocumentChunk

- Entity_MatchDocumentsResult
- Entity_ChatRequest
- Entity_ChatResponse
- Entity_SyncResponse
- Entity_DocumentResponse
- Entity_OpenAIMessage
- Entity_OpenAIChatRequest
- Entity_OpenAIChoice

- Entity_OpenAIUsage
- Entity_OpenAIChatResponse

4.3.6.2 *Xác định các lớp biên*

Từ các use cases chúng ta đưa ra danh sách các lớp biên tương ứng:

- Boundary_RootAPI
- Boundary_ChatAPI
- Boundary_SyncAPI
- Boundary_ListDocumentsAPI
- Boundary_DeleteDocumentAPI
- Boundary_HealthCheckAPI
- Boundary_OpenAI_ListModelsAPI
- Boundary_OpenAI_ChatCompletionsAPI
- BoundaryModel_ChatRequest
- BoundaryModel_ChatResponse
- BoundaryModel_SyncResponse
- BoundaryModel_DocumentResponse
- BoundaryModel_OpenAIMessage
- BoundaryModel_OpenAIChatRequest
- BoundaryModel_OpenAIChoice


4.3.6.3 *Xác định các lớp điều khiển*

Từ các use cases chúng ta đưa ra danh sách các lớp điều khiển tương ứng:


- Ctrl_RAGChain
- Ctrl_SyncService
- Ctrl_SupabaseVectorStore
- Ctrl_OpenAIAdapter

4.3.6.4 *Biểu đồ lớp phân tích*


- Use case Đăng ký




- Use case Đăng nhập




- Use case Đăng xuất




- Use case Nhập prompt




- Use case New chat




- Use case Tìm kiếm hội thoại




- Use case Đổi tên hội thoại




- Use case Lưu trữ hội thoại




- Use case Xóa hội thoại




- Use case Chia sẻ hội thoại



- Use case Tải xuống hội thoại



- Use case Tải file lên Google Drive




4.3.6.5 Thiết kế cơ sở dữ liệu

Xây dựng 2 bảng để lưu trữ dữ liệu:

- **Document**(id, name, source_type, drive_file_id, file_size, created_at, updated_at)
- **Document_chunk**(id, document_id, content, embedding, chunk_index, metadata, created_at)

✓ **Ràng buộc tham chiếu:**

Document (id) **Document_chunk** (document_id)



4.3.7 Thiết kế API

4.3.7.1 API chat (Chat endpoint)

- URL: **/chat**

- Method: **POST**
- Input:
 - question: Câu hỏi người dùng gửi lên hệ thống.
 - top_k (optional): Số lượng đoạn ngữ cảnh (chunks) tối đa được truy
- Output:
 - question: Câu hỏi ban đầu.
 - answer: Câu trả lời do RAG sinh ra.
 - sources: Danh sách nguồn tham chiếu (metadata + nội dung chunk) được dùng để tạo câu trả lời.
 - num_sources: Số lượng nguồn tham chiếu thực tế.

4.3.7.2 API đồng bộ tài liệu từ Google Drive

- URL: **/sync**
- Method: **POST**
- Input: *không có input*
- Output:
 - total_files: Tổng số file đọc được trong folder Google Drive cấu hình.
 - processed: Số file được xử lý (load → chunk → embedding → upsert).
 - skipped: Số file bỏ qua (ví dụ: không thay đổi / không hỗ trợ định dạng / đã tồn tại).
 - errors: Số file lỗi trong quá trình xử lý.
 - new_chunks: Tổng số chunks mới được tạo và lưu vào DB.
 - error_details: Danh sách chi tiết lỗi (nếu có).

4.3.7.3 API lấy danh sách documents trong DB

- URL: **/documents**
- Method: **GET**
- Input: *không có input*
- Output: List[DocumentResponse]
 - id: ID của document trong DB (documents.id).
 - name: Tên file.
 - source_type: Loại file (pdf|docx|xlsx).
 - drive_file_id: ID file Google Drive.
 - created_at: Thời điểm tạo record.

4.3.7.4 API xóa một document và toàn bộ chunks liên quan

- URL: **/documents/{document_id}**
- Method: **DELETE**
- Input:

- document_id (path param): ID của document trong DB.
- Output:
 - JSON message: {"message": "Document {document_id} deleted successfully"}

4.3.7.5 API health check

- URL: /health
- Method: GET
- Input: *không có input*
- Output:
 - JSON: {"status": "healthy"}

4.3.7.6 API list models

- URL: /v1/models
- Method: GET
- Input: *không có input*
- Output:
 - JSON theo chuẩn OpenAI Model List, trong đó model id chính là: rag-chatbot.

4.3.7.7 API chat completions

- URL: /v1/chat/completions
- Method: **POST**
- Input: OpenAIChatRequest
 - model: mặc định "rag-chatbot"
 - messages: danh sách tin nhắn theo chuẩn OpenAI (role, content)
 - stream (optional)
 - temperature (optional)
 - max_tokens (optional)
- Output: OpenAIChatResponse
 - id, object, created, model
 - choices: danh sách OpenAIChoice (trả 1 choice)
 - usage: prompt_tokens, completion_tokens, total_tokens

4.3.8 Hướng dẫn cài đặt


Yêu cầu:

- Tài khoản google
- Tài khoản supabase
- Tài khoản docker


- Thiết bị để chạy dự án (Trong trường hợp này sử dụng Windows 11)
- Python 3.10 trở lên (tải tại python.org)

Lấy các api key cần thiết (Google Gemini API Key)

- Vào trang Makersuite(<https://makersuite.google.com/app/apikey>)
- Đăng nhập bằng tài khoản google




- Tạo API key



- Copy key

Google Drive api

- Vào trang google console (<https://console.cloud.google.com>)
- Tạo mới project (hoặc chọn project có sẵn)



- Chọn project vừa tạo, sau đó tạo OAuth 2.0 Client

Google Cloud CHATBOT Search (/) for resources, docs, products, and more Search

You are now incurring charges in your billing account My Billing Account, as of January 7, 2026. [Learn more](#)

Google Auth Platform / Clients

Overview Clients + Create client Delete Restore deleted OAuth clients

OAuth 2.0 Client IDs

☐	Name	Creation date ↓	Type	Client ID
☐	chatbotAcc	Jan 7, 2026	Web application	787865329456-bt79...

- Setup client cho dự án

← Create OAuth client ID

A client ID is used to identify a single app to Google's OAuth servers. If your app runs on multiple platforms, each will need its own client ID. See [Setting up OAuth 2.0](#) for more information. [Learn more](#) about OAuth client types.

Application type *
Web application

Name *
chatbotClient

The name of your OAuth 2.0 client. This name is only used to identify the client in the console and will not be shown to end users.

i The domains of the URIs you add below will be automatically added to your [OAuth consent screen](#) as [authorized domains](#).

Authorized JavaScript origins ⓘ
For use with requests from a browser

+ Add URI

Authorized redirect URIs ⓘ
For use with requests from a web server

+ Add URI

Note: It may take 5 minutes to a few hours for settings to take effect

verification?project=chatbot-483516

- Sau đó tải file json về và đổi tên thành “credentials.json” và đặt vào thư mục gốc của dự án

OAuth client created

The client ID can always be accessed from Clients tab under Google Auth Platform.



OAuth is limited to 100 [sensitive scope logins](#) until the [OAuth consent screen](#) is verified. This may require a verification process that can take several days.

Client ID	707065329456-089beqse2avoc9gg38josmv5pgka7hn8.apps.googleusercontent.com
-----------	--




Starting in June 2025, you will no longer be able to view or download the client secret once you close this dialog. Make sure you have copied or downloaded the information below and securely stored it.

Client secret	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
Creation date	January 12, 2026, 2:02:40 PM GMT+7
Status	✓ Enabled

↓ Download JSON

OK



Supabase

- Đăng ký tài khoản tại supabase.com
- Tạo project cho dự án

Create a new project
Your project will have its own dedicated instance and full Postgres database.
An API will be set up so you can easily interact with your new database.

Organization: FREE ▼

Project name:

Database password: Copy Go

Note: If using the Postgres connection string, you will need to percent-encode the password

This password is strong. [Generate a password.](#)

Region: ▼

Select the region closest to your users for the best performance.

[SECURITY OPTIONS >](#)

[ADVANCED CONFIGURATION >](#)

Cancel Create new project

- Vào Setting > API Key để lấy: Project Url, Project Api key

Connect to your project
Interact with your database through the [Supabase client libraries](#) and your API keys.

API settings Docs

PROJECT API
Your API is secured behind an API gateway which requires an API Key for every request.
You can use the parameters below to use Supabase client libraries.

Project URL: Copy

A RESTful endpoint for querying and managing your database.


Publishable API Key: Copy

This key is safe to use in a browser if you have enabled Row Level Security (RLS) for your tables and configured policies. You may also use the secret key which can be found [here](#) to bypass RLS.

Choose your preferred framework
Connect to your project from a variety of frameworks, ORMs, an MCP server, or even directly via connection string.

Connect

- Vào SQL Editor để chạy script tạo bảng cho dự án



Cài đặt python cho thiết bị:

- Vào trang chủ python.org

Python version	Maintenance status		First released	End of support	Release schedule
3.15	pre-release	Download	2026-10-07 (planned)	2031-10	PEP 790
3.14	bugfix	Download	2025-10-07	2030-10	PEP 745
3.13	bugfix	Download	2024-10-07	2029-10	PEP 719
3.12	security	Download	2023-10-02	2028-10	PEP 693
3.11	security	Download	2022-10-24	2027-10	PEP 664
3.10	security	Download	2021-10-04	2026-10	PEP 619
3.9	end of life, last release was 3.9.25	Download	2020-10-05	2025-10-31	PEP 596


Looking for a specific release?
Python releases by version number:

Release version	Release date		Click for more
Python 3.13.7	Aug. 14, 2025	Download	Release notes
Python 3.13.6	Aug. 6, 2025	Download	Release notes
Python 3.13.5	June 11, 2025	Download	Release notes
Python 3.13.4	June 3, 2025	Download	Release notes
Python 3.13.3	April 8, 2025	Download	Release notes

- Tải python về và cài đặt

Cài đặt docker cho thiết bị:

- Vào trang <https://www.docker.com/products/docker-desktop/>
- Chọn download docker phù hợp với thiết bị đang sử dụng



- Sau khi cài đặt xong thì bật ứng dụng lên
- Cài đặt thư viện python cho dự án:
- Mở terminal/command prompt, di chuyển vào thư mục dự án và chạy:
`pip install -r requirements.txt`

Đợi khoảng 2-3 phút để nó cài hết các thư viện cần thiết.

```
C:\Windows\System32\cmd.exe
Microsoft Windows [Version 10.0.19045.6456]
(c) Microsoft Corporation. All rights reserved.

D:\AI\chatbot>pip install -r requirements.txt
```

```
C:\Windows\System32\cmd.exe
Microsoft Windows [Version 10.0.19045.6456]
(c) Microsoft Corporation. All rights reserved.

D:\AI\chatbot>pip install -r requirements.txt
Requirement already satisfied: google-api-python-client in c:\users\dungtq4\appdata\local\programs\python\python313\lib\site-packages (from -r requirements.txt (line 2)) (2.187.0)
Requirement already satisfied: google-auth-http2 in c:\users\dungtq4\appdata\local\programs\python\python313\lib\site-packages (from -r requirements.txt (line 3)) (0.3.0)
Requirement already satisfied: google-auth-oauthlib in c:\users\dungtq4\appdata\local\programs\python\python313\lib\site-packages (from -r requirements.txt (line 4)) (1.2.3)
Requirement already satisfied: google-generativeai in c:\users\dungtq4\appdata\local\programs\python\python313\lib\site-packages (from -r requirements.txt (line 5)) (0.8.6)
Requirement already satisfied: supabase in c:\users\dungtq4\appdata\local\programs\python\python313\lib\site-packages (from -r requirements.txt (line 8)) (2.27.1)
Requirement already satisfied: langchain in c:\users\dungtq4\appdata\local\programs\python\python313\lib\site-packages (from -r requirements.txt (line 11)) (1.0.2)
Requirement already satisfied: langchain-google-genai in c:\users\dungtq4\appdata\local\programs\python\python313\lib\site-packages (from -r requirements.txt (line 12)) (4.1.1)
Requirement already satisfied: langchain-community in c:\users\dungtq4\appdata\local\programs\python\python313\lib\site-packages (from -r requirements.txt (line 13)) (0.4)
Requirement already satisfied: pypdf in c:\users\dungtq4\appdata\local\programs\python\python313\lib\site-packages (from -r requirements.txt (line 16)) (6.1.3)
Requirement already satisfied: python-docx in c:\users\dungtq4\appdata\local\programs\python\python313\lib\site-packages (from -r requirements.txt (line 17)) (1.2.0)
Requirement already satisfied: openpyxl in c:\users\dungtq4\appdata\local\programs\python\python313\lib\site-packages (from -r requirements.txt (line 18)) (3.1.5)
Requirement already satisfied: fastapi in c:\users\dungtq4\appdata\local\programs\python\python313\lib\site-packages (from -r requirements.txt (line 21)) (0.128.0)
Requirement already satisfied: pydantic in c:\users\dungtq4\appdata\local\programs\python\python313\lib\site-packages (from -r requirements.txt (line 22)) (2.12.2)
```

Cấu hình file .env: Tại thư mục của dự án, mở file ‘.env’ và điền các thông tin api key vừa setup ở bước trên

```
.env
1 # Google API Keys
2 GOOGLE_API_KEY=AIzaSyBU17rsDhlmwTuk_UPVnK1rmp_rCUjJ5iE
3 GOOGLE_CLIENT_ID=707065329456-bt79o44judbone5bjqf112ru0hhu0nabr.apps.googleusercontent.com
4 GOOGLE_CLIENT_SECRET=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
5 # Google Drive
6 GOOGLE_DRIVE_FOLDER_ID=1EjQlY140heVoKnz7TkC0-qwHa8Naacjk
7
8 # Supabase
9 SUPABASE_URL=https://btupdyqqyzdkgjajins.supabase.co
10 SUPABASE_KEY=sb_publishable_tMUw8AuNviZ5Anb1Ry6wNw_DEkG5Qer
11
12 # Server
13 PORT=8000
14
```

- Lưu ý: GOOGLE_DRIVE_FOLDER_ID lấy từ URL của folder trên Google Drive. Ví dụ: <https://drive.google.com/drive/folders/1ABC123xyz> thì ID là: 1ABC123xyz

Chạy dự án (Khởi động backend (api))

- Mở terminal trong thư mục dự án và điền “python main.py” và enter
- Bạn sẽ thấy dòng chữ: "INFO: Uvicorn running on <http://0.0.0.0:8000>" Để nó chạy ngầm.

Đồng bộ tài liệu từ Google Drive:

- Lần đầu tiên chạy, bạn cần đồng bộ tài liệu vào database.
- Mở trình duyệt postman, sử dụng POST method, truy cập: <http://localhost:8000/sync>
- Nó sẽ yêu cầu bạn đăng nhập Google để cấp quyền truy cập Drive.

- Sau khi đăng nhập xong, nó sẽ tự động tải và xử lý các file PDF, Word, Excel trong folder bạn đã chỉ định. Quá trình này có thể mất vài phút tùy số lượng tài liệu.


Khởi động giao diện web

- Mở terminal MỚI (giữ nguyên terminal cũ đang chạy python main.py)
- Di chuyển vào thư mục UI: `cd UI/open-webui`
- Chạy Docker: `docker compose up -d`
- Đợi khoảng 1-2 phút để Docker tải và khởi động các container.


Truy cập giao diện chat

- Lần đầu tiên, bạn sẽ cần:
 - Tạo tài khoản (tài khoản đầu tiên sẽ là Admin)
 - Vào Settings > Connections
 - Thêm kết nối OpenAI API:
 - + API Base URL: `http://host.docker.internal:8000/v1`
 - + API Key: sk-123 (gõ gì cũng được, không quan trọng)
 - Save lại


4.3.9 Thiết kế giao diện




Hình 6: Trang chủ hệ thống




Hình 7: Chức năng tìm kiếm




Hình 8: Chức năng ghi chú




Hình 9: Danh sách Mô hình trong không gian làm việc




Hình 10: Danh sách kiến thức trong không gian làm việc




Hình 11: Danh sách Prompt trong không gian làm việc




Hình 12: Danh sách Tools trong không gian làm việc




Hình 13: Các thao tác nhanh của chat




Hình 14: Màn hình quản trị người sử dụng



Hình 15: Màn hình quản trị đánh giá



Hình 16: Màn hình quản trị chức năng



Hình 17: Màn hình cài đặt

id	document_id	content	embedding	chunk_index	metadata	created_at
1	1	QUY ĐỊNH VỀ CÔNG TÁC TỔ CHỨC TH	[0.04150987,0.0596452]	0	["source_type":"doc","document_name":"6. Quy định về tổ chức thi t	2026-01-07 15:31:38.745207+00
2	1	Phòng thi trực tuyến là phòng thi được t	[0.03663798,0.0632460]	1	["source_type":"doc","document_name":"6. Quy định về tổ chức thi t	2026-01-07 15:31:38.745207+00
3	1	Sự cố trong quá trình thi là những sự việc	[0.03236125,0.07083922]	2	["source_type":"doc","document_name":"6. Quy định về tổ chức thi t	2026-01-07 15:31:38.745207+00
4	1	chấm thi - Cán bộ coi thi thu và nộp bài t	[0.00868947,0.0563413]	3	["source_type":"doc","document_name":"6. Quy định về tổ chức thi t	2026-01-07 15:31:38.745207+00
5	1	Phòng Đào tạo - Phối hợp cùng các bộ m	[0.02115595,0.0520558]	4	["source_type":"doc","document_name":"6. Quy định về tổ chức thi t	2026-01-07 15:31:38.745207+00
6	1	Các đề thi phải thống nhất với câu trúc đ	[0.01483227,0.0530843]	5	["source_type":"doc","document_name":"6. Quy định về tổ chức thi t	2026-01-07 15:31:38.745207+00
7	1	Trình tự triển khai tương tự như trên. Đi	[0.019404189,0.0421661]	6	["source_type":"doc","document_name":"6. Quy định về tổ chức thi t	2026-01-07 15:31:38.745207+00
8	1	Trách nhiệm của cán bộ coi thi (CBCT) t	[0.03744925,0.0320041]	7	["source_type":"doc","document_name":"6. Quy định về tổ chức thi t	2026-01-07 15:31:38.745207+00
9	1	- Khi hết giờ làm bài thì với hình thức tự t	[0.022483744,0.044535]	8	["source_type":"doc","document_name":"6. Quy định về tổ chức thi t	2026-01-07 15:31:38.745207+00
10	1	Đổi với thi trực tuyến trực tuyến, CBCT	[0.025187608,0.0476984]	9	["source_type":"doc","document_name":"6. Quy định về tổ chức thi t	2026-01-07 15:31:38.745207+00
11	1	Trách nhiệm của sinh viên/học viên - Tru	[0.03072015,0.0492322]	10	["source_type":"doc","document_name":"6. Quy định về tổ chức thi t	2026-01-07 15:31:38.745207+00
12	1	Không gian nơi sinh viên/học viên ngồi là	[0.0036514406,0.04209]	11	["source_type":"doc","document_name":"6. Quy định về tổ chức thi t	2026-01-07 15:31:38.745207+00
13	1	Phải giữ gìn trật tự, im lặng trong ph	[0.023742005,0.0323961]	12	["source_type":"doc","document_name":"6. Quy định về tổ chức thi t	2026-01-07 15:31:38.745207+00
14	1	Sinh viên/học viên cần ghi rõ số thứ tự t	[0.041775018,0.0266456]	13	["source_type":"doc","document_name":"6. Quy định về tổ chức thi t	2026-01-07 15:31:38.745207+00
15	1	Tất cả các sự cố cần được ghi rõ vào bi	[0.02077731,0.04994937]	14	["source_type":"doc","document_name":"6. Quy định về tổ chức thi t	2026-01-07 15:31:38.745207+00
16	1	:- Để cho sinh viên tự do sử dụng điện th	[0.021327129,0.06011456]	15	["source_type":"doc","document_name":"6. Quy định về tổ chức thi t	2026-01-07 15:31:38.745207+00
17	1	Những hình thức kỷ luật quy định ở các đ	[0.016724244,0.0395733]	16	["source_type":"doc","document_name":"6. Quy định về tổ chức thi t	2026-01-07 15:31:38.745207+00
18	1	Các hình thức xử lý kỷ luật đối với sinh v	[0.03548876,0.0299384]	17	["source_type":"doc","document_name":"6. Quy định về tổ chức thi t	2026-01-07 15:31:38.745207+00
19	1	ánh sách phòng thi". Sinh viên/học viên b	[0.034778052,0.030459]	18	["source_type":"doc","document_name":"6. Quy định về tổ chức thi t	2026-01-07 15:31:38.745207+00
20	1	Đình chỉ học tập 1 năm, áp dụng đối với s	[0.041890886,0.039499]	19	["source_type":"doc","document_name":"6. Quy định về tổ chức thi t	2026-01-07 15:31:38.745207+00
21	1	Việc xử lý kỷ luật sinh viên phải được c	[0.018369991,0.0492305]	20	["source_type":"doc","document_name":"6. Quy định về tổ chức thi t	2026-01-07 15:31:38.745207+00

Hình 18: DB Supabase

4.3.10 Đánh giá ứng dụng

4.3.10.1 Mục tiêu đánh giá

Mục tiêu của việc đánh giá ứng dụng nhằm kiểm tra mức độ đáp ứng của hệ thống chatbot truy vấn tài liệu so với các yêu cầu đặt ra ban đầu, bao gồm:

- Khả năng trả lời câu hỏi dựa trên nội dung tài liệu thực tế
- Độ chính xác và mức độ phù hợp của câu trả lời
- Khả năng trích dẫn nguồn thông tin rõ ràng
- Hiệu quả trong việc giảm thời gian tra cứu thông tin

- Trải nghiệm người dùng khi tương tác với hệ thống

4.3.10.2 Phương pháp đánh giá

Ứng dụng được đánh giá thông qua các phương pháp sau:

- Đánh giá chức năng: kiểm tra các chức năng chính của hệ thống như đồng bộ dữ liệu, truy vấn, sinh câu trả lời và hiển thị nguồn tham khảo.
- Đánh giá chất lượng câu trả lời: so sánh nội dung trả lời của chatbot với nội dung thực tế trong tài liệu gốc.
- Đánh giá hiệu quả sử dụng: so sánh thời gian tra cứu thông tin giữa phương pháp thủ công và sử dụng chatbot.
- Đánh giá trải nghiệm người dùng: sử dụng thang đo MOS (Mean Opinion Score) để thu thập phản hồi từ người dùng thử nghiệm.

4.3.10.3 Đánh giá chức năng hệ thống

Kết quả đánh giá cho thấy hệ thống đáp ứng đầy đủ các chức năng đã đề ra, bao gồm:

- Đồng bộ và xử lý dữ liệu từ Google Drive hoạt động ổn định
- Hệ thống tự động chia nhỏ và lưu trữ dữ liệu dưới dạng vector embedding
- Chatbot có thể tiếp nhận câu hỏi bằng ngôn ngữ tự nhiên
- Câu trả lời được sinh dựa trên nội dung tài liệu và có kèm danh sách nguồn tham khảo
- Giao diện hội thoại hiển thị rõ ràng, dễ sử dụng

Không ghi nhận lỗi nghiêm trọng trong quá trình thử nghiệm các chức năng chính.

4.3.10.4 Đánh giá chất lượng câu trả lời

Chất lượng câu trả lời được đánh giá dựa trên các tiêu chí:

- Độ liên quan giữa câu hỏi và nội dung trả lời
- Mức độ chính xác so với tài liệu gốc
- Tính đầy đủ thông tin
- Khả năng trích dẫn nguồn

Kết quả thử nghiệm cho thấy:

- Phần lớn câu trả lời bám sát nội dung tài liệu
- Các thông tin quan trọng đều được trích xuất đúng ngữ cảnh
- Danh sách nguồn được hiển thị rõ ràng, cho phép người dùng kiểm chứng lại thông tin

Trong một số trường hợp câu hỏi quá chung chung hoặc tài liệu chứa nội dung chưa rõ ràng, câu trả lời có xu hướng tổng quát, tuy nhiên vẫn đảm bảo không sinh nội dung ngoài phạm vi dữ liệu.

4.3.10.5 Đánh giá hiệu quả tra cứu thông tin

Hiệu quả tra cứu được đánh giá bằng cách so sánh thời gian tìm kiếm thông tin theo hai phương pháp:

- Tra cứu thủ công trong tài liệu PDF/Word
- Tra cứu thông qua chatbot

Kết quả cho thấy:

- Thời gian tra cứu thủ công trung bình từ vài phút đến hàng chục phút tùy độ phức tạp của tài liệu
- Thời gian nhận câu trả lời từ chatbot chỉ mất vài giây cho tới một phút
- Hệ thống giúp giảm đáng kể thời gian tra cứu và công sức đọc tài liệu

Điều này cho thấy chatbot mang lại hiệu quả rõ rệt trong việc hỗ trợ khai thác thông tin từ kho tài liệu số.

4.3.10.6 Đánh giá trải nghiệm người dùng (MOS)

Để đánh giá mức độ hài lòng của người dùng, đề tài sử dụng thang đo MOS (Mean Opinion Score) với các mức điểm từ 1 đến 5, trong đó:

- 1: Rất không hài lòng
- 2: Không hài lòng
- 3: Bình thường
- 4: Hài lòng
- 5: Rất hài lòng

Người dùng tham gia thử nghiệm đánh giá các tiêu chí sau:

- Dễ sử dụng của giao diện
- Độ rõ ràng của câu trả lời
- Mức độ tin cậy của nguồn trích dẫn
- Tính hữu ích của ứng dụng trong công việc

Kết quả cho thấy điểm MOS trung bình đạt mức **từ 4 trở lên**, phản ánh người dùng nhìn chung hài lòng với hệ thống và đánh giá cao khả năng hỗ trợ tra cứu tài liệu của chatbot.

4.3.10.7 Nhận xét chung

Qua quá trình đánh giá, có thể nhận thấy hệ thống chatbot truy vấn tài liệu dựa trên mô hình RAG đáp ứng tốt các mục tiêu đề ra ban đầu. Ứng dụng không chỉ hỗ trợ trả lời câu hỏi dựa trên dữ liệu thực tế mà còn giúp người dùng tiết kiệm thời gian, nâng cao hiệu quả khai thác thông tin và tăng tính minh bạch thông qua cơ chế trích dẫn nguồn.

Khi người dùng đặt câu hỏi không thuộc phạm vi các tài liệu đã được cung cấp trong thư mục, mô hình Gemini có thể trả lời dựa trên kiến thức tổng quát và tham chiếu thông tin từ các nguồn bên ngoài (ví dụ Internet). Điều này giúp mở rộng khả năng hỗ trợ của chatbot trong một số tình huống tra cứu kiến thức chung, tuy nhiên nội dung trả lời có thể không phản ánh trực tiếp từ tài liệu tham chiếu của hệ thống.

Tuy nhiên, hệ thống vẫn còn một số điểm cần tiếp tục tối ưu để nâng cao độ ổn định và độ chính xác. Do sử dụng mô hình Gemini phiên bản miễn phí, chất lượng sinh câu trả lời trong một số trường hợp chưa thực sự đồng đều (đặc biệt với câu hỏi dài, câu hỏi yêu cầu tổng hợp nhiều ý hoặc khi ngữ cảnh truy hỏi chưa đầy đủ). Dù vậy, kết quả đánh giá cho thấy hệ thống có tiềm năng ứng dụng và phù hợp để tiếp tục phát triển, mở rộng trong tương lai.

CHƯƠNG 5 HẠN CHẾ VÀ PHƯƠNG HƯỚNG PHÁT TRIỂN

5.1 Hạn chế tồn đọng

Ứng dụng có ý nghĩa nhân văn và tính thực tiễn rất cao, tuy nhiên vẫn còn tồn đọng một số hạn chế nhất định, cần giải quyết và phát triển để ứng dụng có thể đưa tới tay người sử dụng như:

- Độ chính xác phụ thuộc vào mô hình AI
- Cần thêm thời gian training, cho mô hình học để tối ưu được độ chính xác

5.2 Phương hướng phát triển

- Nghiên cứu thêm một số tính năng cải thiện Chatbot ví dụ như: Đọc được hình ảnh, nghe được record,... và trả ra được kết quả đúng.
- Đào tạo mô hình phát hiện nhiều từ khóa hơn, cải thiện độ chính xác khi tìm kiếm.
- Hoàn thiện ứng dụng, tối ưu hóa hiệu năng, thời gian phản hồi.
- Ứng dụng thêm được nhiều công nghệ mới, phù hợp với quá trình phát triển của AI, ví dụ như tương lai, có thêm thuật toán mới, tối ưu hơn, chính xác hơn thì sẽ áp dụng vào hệ thống.

TÀI LIỆU THAM KHẢO

- [1] P. Lewis, E. Perez, A. Piktus, et al., “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks,” arXiv:2005.11401, 2020. [Online]. Available: <https://arxiv.org/abs/2005.11401>.
- [2] V. Karpukhin, B. Oguz, S. Min, et al., “Dense Passage Retrieval for Open-Domain Question Answering,” arXiv:2004.04906, 2020. [Online]. Available: <https://arxiv.org/abs/2004.04906>.
- [3] N. Reimers and I. Gurevych, “Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks,” arXiv:1908.10084, 2019. [Online]. Available: <https://arxiv.org/abs/1908.10084>.
- [4] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding,” in Proc. NAACL, 2019. [Online]. Available: <https://arxiv.org/abs/1810.04805>.
- [5] Pinecone, “Pinecone Documentation,” [Online]. Available: <https://docs.pinecone.io/>.
- [6] LangChain, “LangChain Documentation,” [Online]. Available: <https://python.langchain.com/docs/>.